

## **Lecture 05b**

Introducción a las CNNs parte 2 -  
Arquitecturas de CNNs

# Controlar el tamaño de salida además del paso

- **Padding (controla el tamaño de la salida junto con stride)**
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning

# Releno

output size

input size

padding pixels per side


kernel size

stride

"floor" function


$$O = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

$$(4 - 3 + 2*0)/1 + 1 = 2$$




No padding, stride=1

$$(5 - 4 + 2*2)/1 + 1 = 6$$



padding=2, stride=1

$$(5 - 3 + 2*0)/2 + 1 = 2$$



No padding, stride=2

## Altamente recomendado

Dumoulin, Vincent, and Francesco Visin. "A guide to convolution arithmetic for deep learning." arXiv preprint arXiv:1603.07285 (2016).

<https://arxiv.org/abs/1603.07285>

# Jerga de Padding

Convolución "valid": Sin padding (el mapa de características se reduce)

Convolución "same": Padding tal que el tamaño de salida es igual al tamaño de entrada

Convenciones comunes de tamaño de kernel:

3x3, 5x5, 7x7 (a veces 1x1 en capas posteriores para reducir canales)

# Padding

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

Suponga que desea utilizar una operación convolucional con paso 1 y mantener las dimensiones de entrada en el mapa de características de salida:

¿Cuánto padding se necesita para que el tamaño del mapa de características sea igual al tamaño de entrada?

$$o = i + 2p - k + 1$$

$$\Leftrightarrow p = (o - i + k - 1)/2$$

$$\Leftrightarrow p = (k - 1)/2$$

# Padding

$$o = i + 2p - k + 1$$

$$\Leftrightarrow p = (o - i + k - 1)/2$$

$$\Leftrightarrow p = (k - 1)/2$$

Probablemente explica por qué las convenciones de tamaño de kernel comunes son 3x3, 5x5, 7x7 (a veces 1x1 en capas posteriores para reducir canales)

# Conceptos familiares ahora en 2D

- Padding (controla el tamaño de la salida junto con stride)
- **Dropout 2D y batchnorm**
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning



# Dropout 2D

- Problema con el dropout regular y las CNN: Es probable que los píxeles adyacentes estén muy correlacionados (por lo tanto, es posible que no ayuden a reducir la "dependencia" tanto como se pretendía originalmente con el dropout)
- Por lo tanto, puede ser mejor eliminar mapas de características completos.

**\*\*La idea proviene de\*\***

Tompson, Jonathan, Ross Goroshin, Arjun Jain, Yann LeCun, and Christoph Bregler.

"Efficient object localization using convolutional networks." In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 648-656. 2015.

[https://www.cv-foundation.org/openaccess/content\\_cvpr\\_2015/html/Tompson\\_Efficient\\_Object\\_Localization\\_2015\\_CVPR\\_paper.html](https://www.cv-foundation.org/openaccess/content_cvpr_2015/html/Tompson_Efficient_Object_Localization_2015_CVPR_paper.html)

# Dropout 2D

- Dropout2d descartará mapas de características completos (canales)

```
import torch

m = torch.nn.Dropout2d(p=0.5)
input = torch.randn(1, 3, 5, 5)
output = m(input)
```

output

```
tensor([[[[-0.0000,  0.0000,  0.0000,  0.0000, -0.0000],
          [ 0.0000, -0.0000,  0.0000,  0.0000,  0.0000],
          [ 0.0000, -0.0000,  0.0000, -0.0000,  0.0000],
          [ 0.0000,  0.0000, -0.0000,  0.0000, -0.0000],
          [-0.0000,  0.0000,  0.0000, -0.0000, -0.0000]],

         [[-3.5274,  0.8163,  0.2440,  1.2410,  1.5022],
          [-1.2455,  6.3875, -2.6224,  0.0261,  1.7487],
          [ 1.6471,  0.7444, -2.1941, -2.0119, -1.5232],
          [ 0.3720, -1.5606,  0.7630,  0.9177, -0.1387],
          [-1.2817, -3.5804,  0.4367, -0.1384, -0.8148]],

         [[-0.0000, -0.0000, -0.0000, -0.0000,  0.0000],
          [ 0.0000, -0.0000, -0.0000, -0.0000,  0.0000],
          [ 0.0000, -0.0000,  0.0000, -0.0000, -0.0000],
          [-0.0000, -0.0000,  0.0000,  0.0000, -0.0000],
          [-0.0000,  0.0000,  0.0000,  0.0000,  0.0000]]]])
```

# BatchNorm 2D

## BatchNorm1d

**CLASS** `torch.nn.BatchNorm1d(num_features, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)`

[\[SOURCE\]](#) 

Applies Batch Normalization over a 2D or 3D input (a mini-batch of 1D inputs with optional additional channel dimension) as described in the paper [Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift](#).

$$y = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

## BatchNorm2d

**CLASS** `torch.nn.BatchNorm2d(num_features, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)`

[\[SOURCE\]](#)

Applies Batch Normalization over a 4D input (a mini-batch of 2D inputs with additional channel dimension) as described in the paper [Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift](#).

$$y = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

# BatchNorm 2D

BatchNorm1d **Las entradas son tensores de rango 2: [N, num\_features]**

```
CLASS torch.nn.BatchNorm1d(num_features, eps=1e-05, momentum=0.1, affine=True,  
                             track_running_stats=True)
```

[\[SOURCE\]](#) [🔗](#)

Applies Batch Normalization over a 2D or 3D input (a mini-batch of 1D inputs with optional additional channel dimension) as described in the paper [Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift](#).

$$y = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

BatchNorm2d **Las entradas son tensores de rango 4: [N, C, H, W]**

```
CLASS torch.nn.BatchNorm2d(num_features, eps=1e-05, momentum=0.1, affine=True,  
                             track_running_stats=True)
```

[\[SOURCE\]](#)

Applies Batch Normalization over a 4D input (a mini-batch of 2D inputs with additional channel dimension) as described in the paper [Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift](#).

$$y = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

En BatchNorm2d, la desviación media y estándar se calculan para  $N * H * W$ , es decir, sobre la dimensión del canal

Fuente: <https://pytorch.org/docs/stable/nn.html>

# BatchNorm 2D

En BatchNorm2d, la desviación media y estándar se calculan para  $N * H * W$ , es decir, sobre la dimensión del canal

```
[1]: import torch.nn as nn
import torch.nn.functional as F

class Model(nn.Module):
    def __init__(self):
        super(Model, self).__init__()

        self.cn1 = nn.Conv2d(3, 192, kernel_size=5,
                             stride=1, padding=2, bias=False)
        self.bn1 = nn.BatchNorm2d(192)

    # ...

[2]: model = Model()

[3]: model.bn1.weight.size()

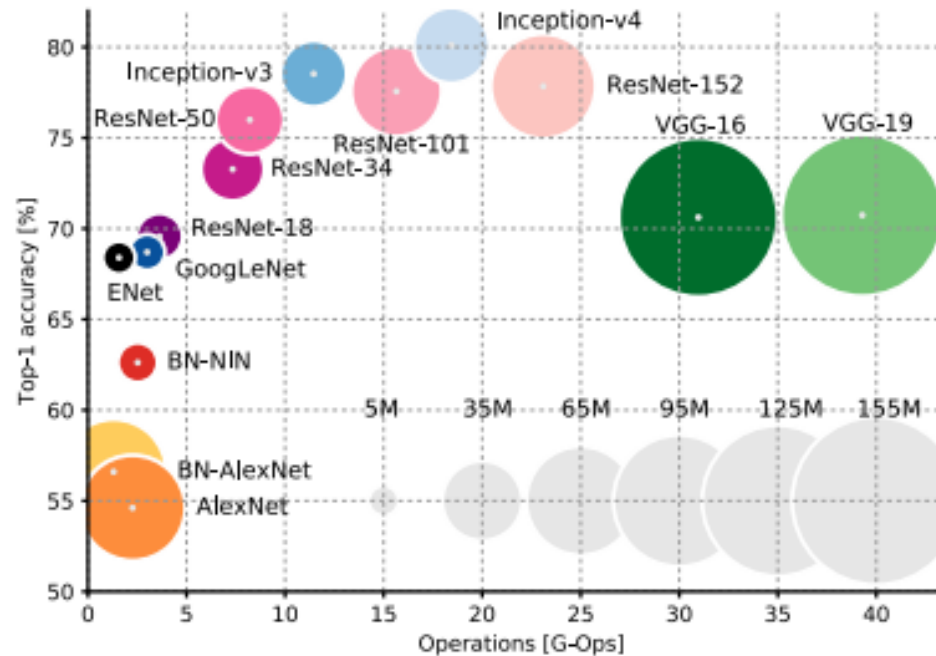
[3]: torch.Size([192])
```

# Revisión de las arquitecturas comunes

- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- **Arquitecturas comunes**
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning


# Revisión de las arquitecturas comunes

Discutiremos algunas arquitecturas CNN comunes adicionales ya que el campo evolucionó bastante desde 2012.



Canziani, A., Paszke, A., & Culurciello, E. (2016). An analysis of deep neural network models for practical applications. Single-crop top-1 validation. arXiv preprint arXiv:1605.07678.

# Revisión de las arquitecturas comunes




Canziani, A., Paszke, A., & Culurciello, E. (2016). An analysis of deep neural network models for practical applications. Single-crop top-1 validation. arXiv preprint arXiv:1605.07678.



# Agregando más capas

- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - **VGG16 (simple, CNN profunda)**
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning

# Revisión de las arquitecturas comunes



Canziani, A., Paszke, A., & Culurciello, E. (2016). An analysis of deep neural network models for practical applications. Single-crop top-1 validation. arXiv preprint arXiv:1605.07678.

# VGG-16

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64	conv3-64	conv3-64	conv3-64
maxpool					
conv3-128	conv3-128	conv3-128	conv3-128	conv3-128	conv3-128
maxpool					
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256
maxpool					
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
maxpool					
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

## Ventajas:

Arquitectura muy simple, conv 3x3, stride = 1, padding "same" , MaxPooling de 2x2

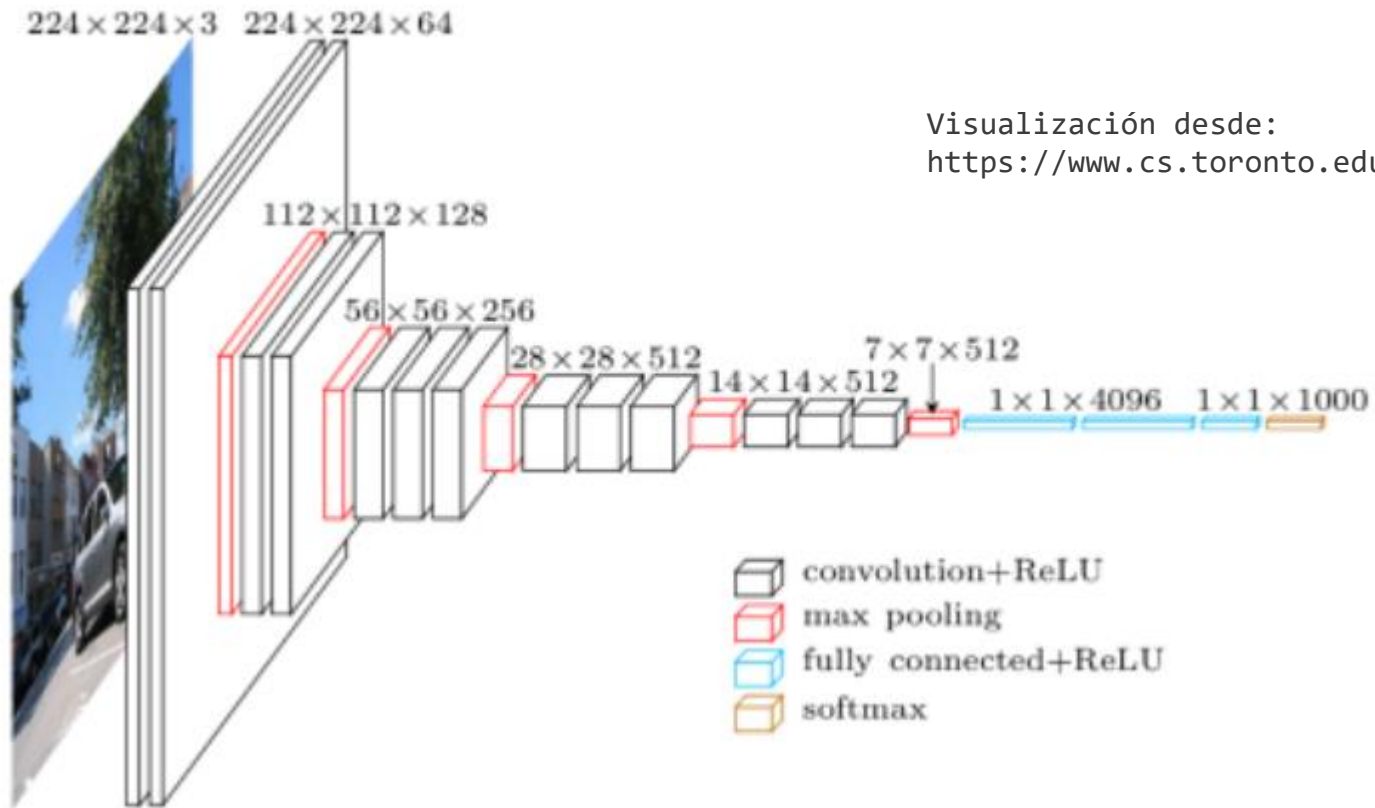
## Desventaja:

Gran cantidad de parámetros y lento (ver diapositiva anterior)

Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).

<https://arxiv.org/abs/1409.1556>

# VGG-16



Visualización desde:  
<https://www.cs.toronto.edu/~frossard/post/vgg16/>

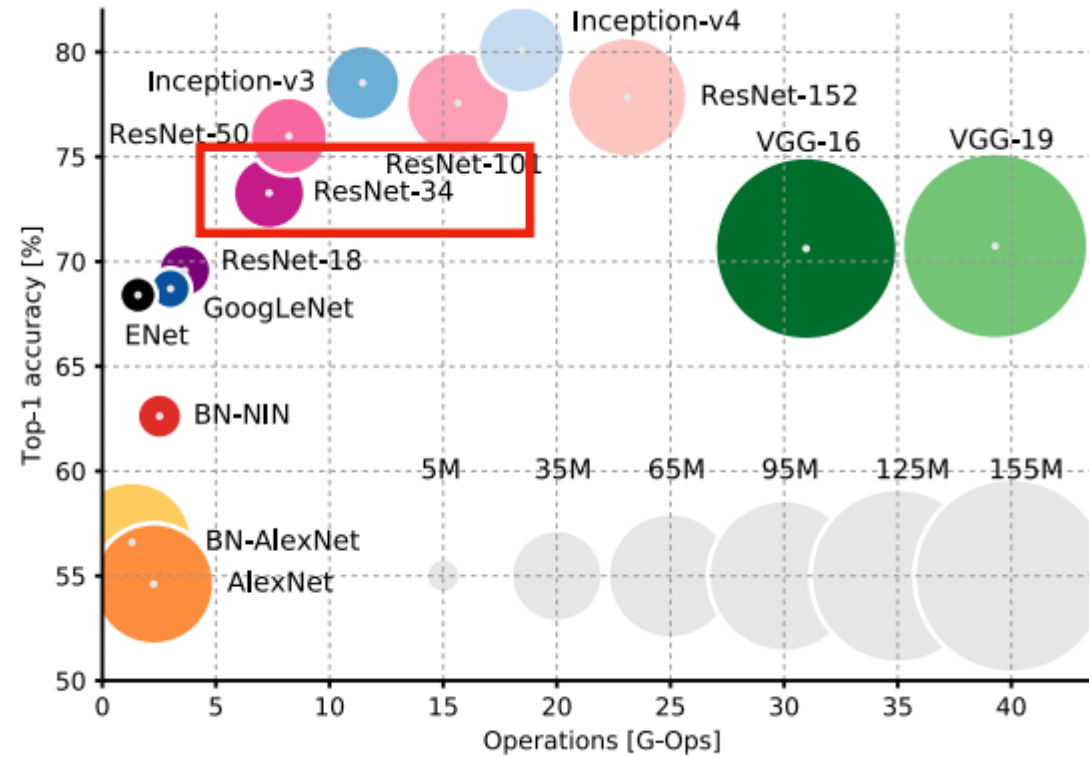
Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).

<https://arxiv.org/abs/1409.1556>

# ¿Podemos agregar más capas? CNN con un simple truco

- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - **ResNet y skip connections**
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning

# Revisión de las arquitecturas comunes



Canziani, A., Paszke, A., & Culurciello, E. (2016). An analysis of deep neural network models for practical applications. Single-crop top-1 validation. arXiv preprint arXiv:1605.07678.

# ResNets

He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778. 2016.

[http://openaccess.thecvf.com/content\\_cvpr\\_2016/html/He\\_Deep\\_Residual\\_Learning\\_CVPR\\_2016\\_paper.html](http://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html)

Con su simple truco de permitir omitir conexiones (la posibilidad de aprender funciones de identidad y omitir capas que no son útiles), ResNets permite implementar arquitecturas muy, muy profundas


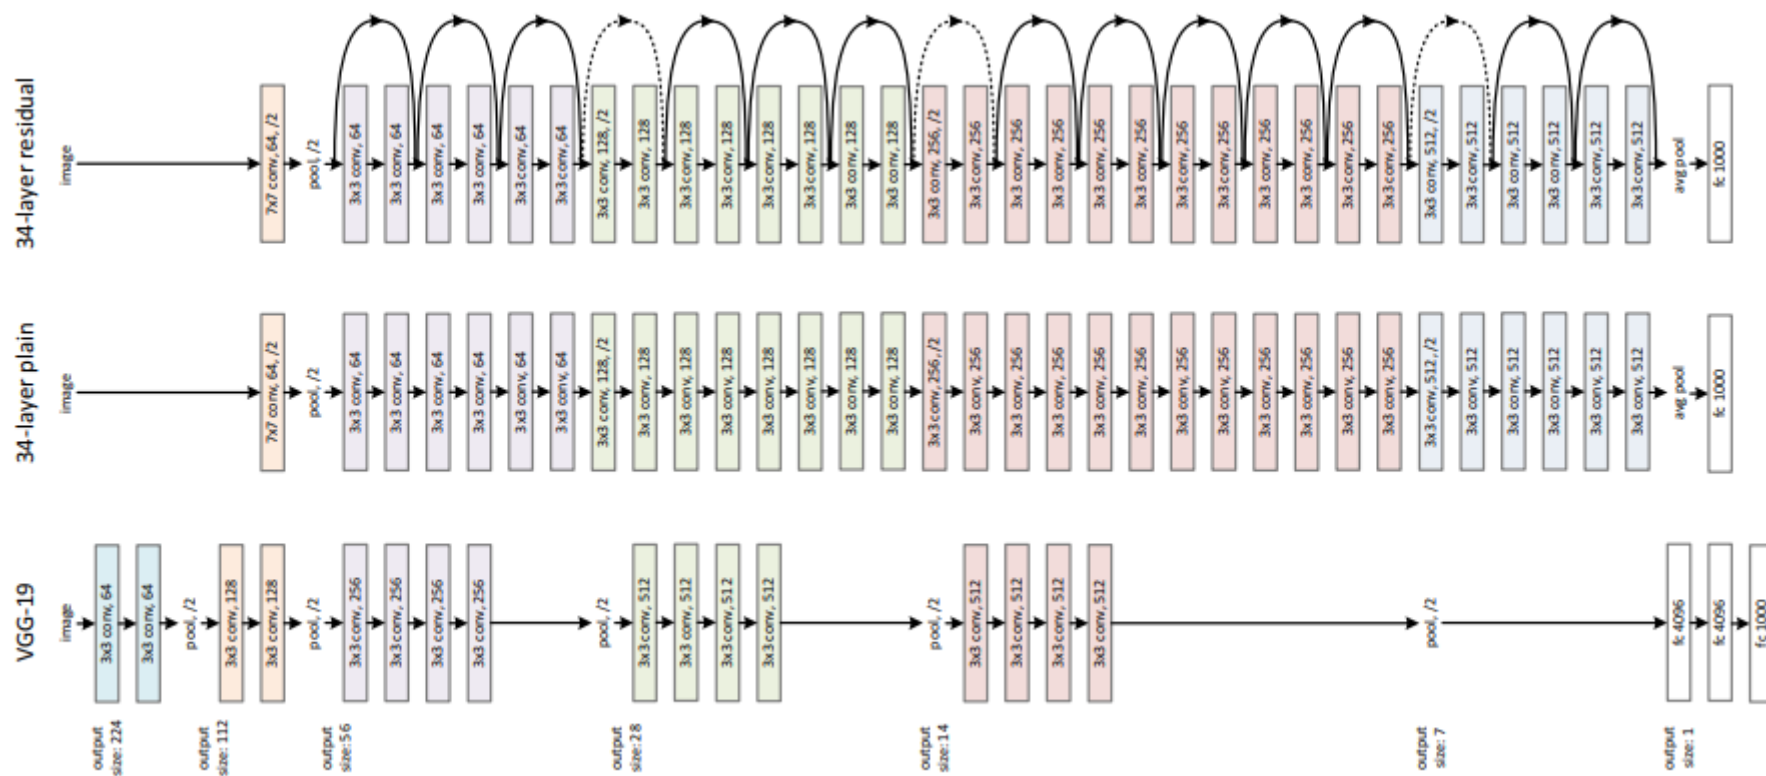


Figure 2. Residual learning: a building block.

# ResNets

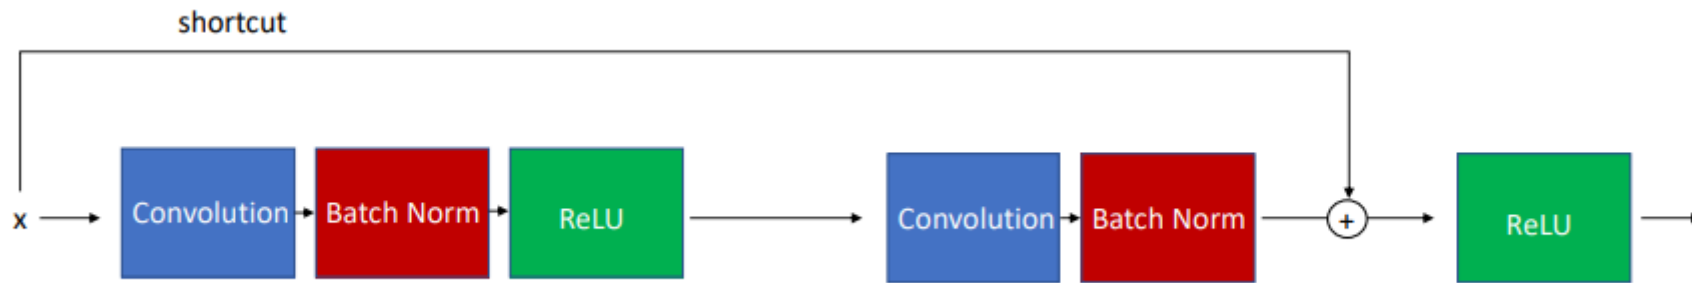
He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "Deep residual learning for image recognition." In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770-778. 2016.

[http://openaccess.thecvf.com/content\\_cvpr\\_2016/html/He\\_Deep\\_Residual\\_Learning\\_CVPR\\_2016\\_paper.html](http://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html)






# ResNets



In general: 
$$a^{(l+2)} = \sigma(z^{(l+2)} + a^{(l)})$$

# ResNets



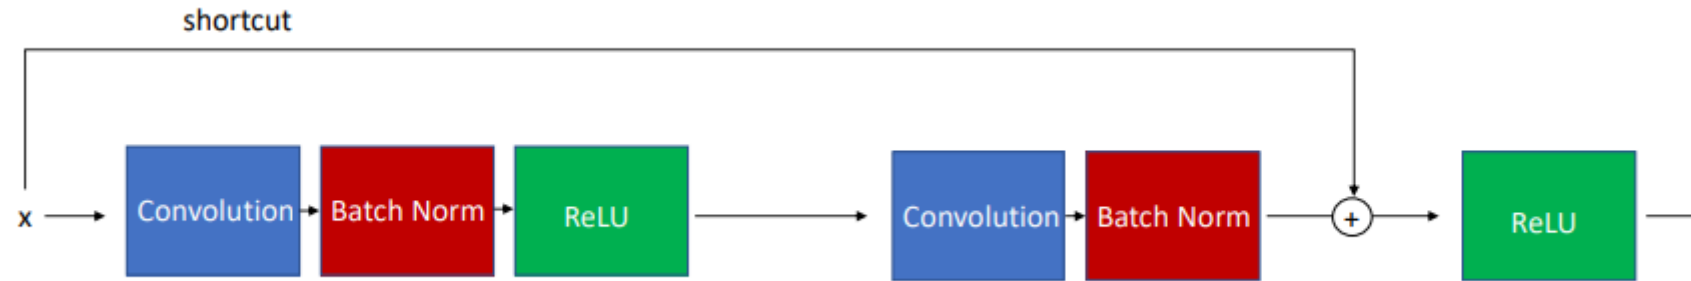
$$\begin{aligned} a^{(l+2)} &= \sigma(z^{(l+2)} + a^{(l)}) \\ &= \sigma(a^{(l+1)}W^{(l+2)} + b^{(l+2)} + a^{(l)}) \end{aligned}$$

Si todos los pesos y el sesgo son cero, entonces

$$= \sigma(a^{(l)}) \underset{\substack{\uparrow \\ \text{debido a ReLU}}}{=} a^{(l)}$$

Función identidad


# ResNets



$$a^{(l+2)} = \sigma(z^{(l+2)} + a^{(l)})$$

Suponemos que tienen la misma dimensión  
(por ejemplo, A través de "la misma"  
convolución)

# ResNets



Bloques residuales alternativos con conexiones de salto, de modo que la entrada pasada a través del atajo se redimensione a las dimensiones de la salida de la ruta principal

# Simplificando CNNs

- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- **Reemplazando Max-Pooling con capas convolucionales**
- Capas convolucionales en lugar de completamente conectadas
- Transfer learning

# "Red totalmente convolucional"

Springenberg, Jost Tobias, Alexey Dosovitskiy, Thomas Brox, and Martin Riedmiller. "Striving for simplicity: The all convolutional net." arXiv preprint arXiv:1412.6806 (2014).

<https://arxiv.org/abs/1412.6806>

**Idea clave:** Reemplace Max Pooling por convoluciones escalonadas (es decir, capas convolucionadas con paso = 2)

Podemos pensar en las "convoluciones escalonadas" como agrupaciones que se pueden aprender

# Agrupación promedio global en la última capa

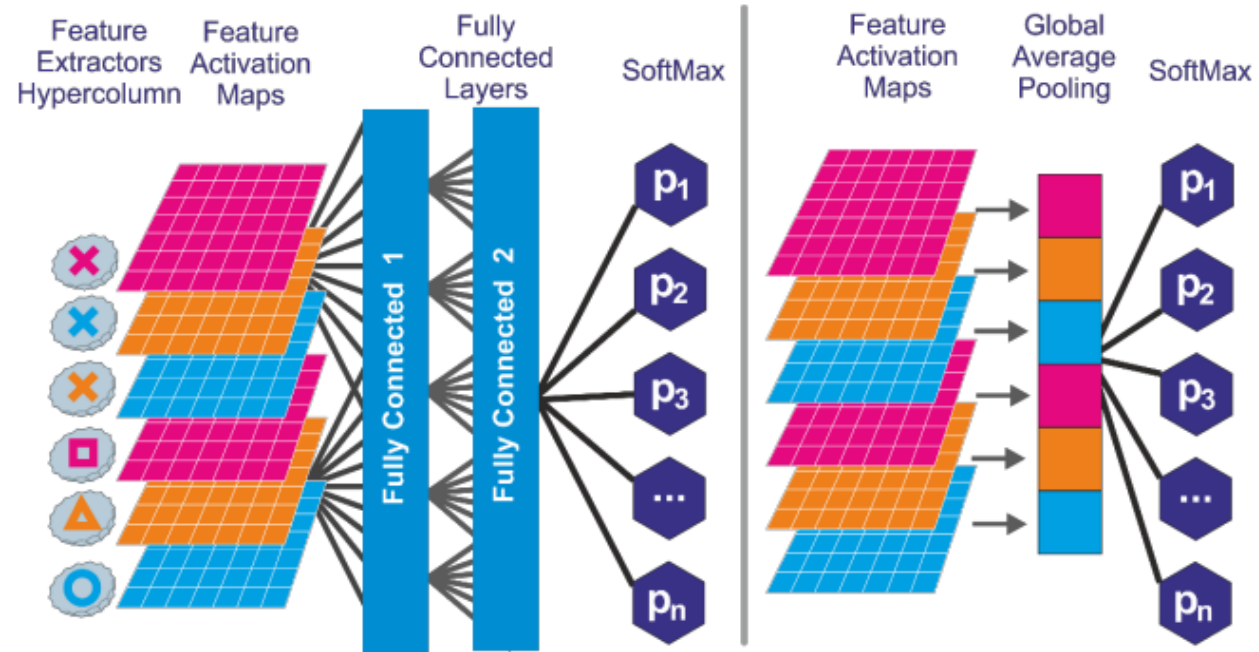


Figure 16: Global average pooling layer replacing the fully connected layers. The output layer implements a Softmax operation with  $p_1, p_2, \dots, p_n$  the predicted probabilities for each class.


Código de Ejemplo



# Simplificando CNNs parte 2


- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- **Capas convolucionales en lugar de completamente conectadas**
- Transfer learning

# Es posible reemplazar capas completamente conectadas por capas convolucionales



Fully connected layer

Recuerde, estos también involucran productos punto entre los campos receptivos y los núcleos.



where  $\mathbf{W}_1 = \begin{bmatrix} w_{1,1} & w_{1,2} \\ w_{1,3} & w_{1,4} \end{bmatrix}$

$\mathbf{W}_2 = \begin{bmatrix} w_{2,1} & w_{2,2} \\ w_{2,3} & w_{2,4} \end{bmatrix}$

```
import torch
```


Assume we have a 2x2 input image:

```
inputs = torch.tensor([[[[1., 2.],  
                          [3., 4.]]]])
```

```
inputs.shape
```

```
torch.Size([1, 1, 2, 2])
```

NCHW



```
fc = torch.nn.Linear(4, 2)
```

```
weights = torch.tensor([[1.1, 1.2, 1.3, 1.4],  
                        [1.5, 1.6, 1.7, 1.8]])
```


```
bias = torch.tensor([1.9, 2.0])
```

```
fc.weight.data = weights
```

```
fc.bias.data = bias
```

```
torch.relu(fc(inputs.view(-1, 4)))
```

```
tensor([[14.9000, 19.0000]], grad_fn=<ReluBackward0>)
```



```
import torch
```

Assume we have a 2x2 input image:

```
inputs = torch.tensor([[[[1., 2.],
                          [3., 4.]]]])
```


```
inputs.shape
```

```
torch.Size([1, 1, 2, 2])
```

```
fc = torch.nn.Linear(4, 2)
weights = torch.tensor([[[1.1, 1.2, 1.3, 1.4],
                          [1.5, 1.6, 1.7, 1.8]]])
bias = torch.tensor([1.9, 2.0])
fc.weight.data = weights
fc.bias.data = bias
```

```
torch.relu(fc(inputs.view(-1, 4)))
```

```
tensor([[14.9000, 19.0000]], grad_fn=<ReluBackward0>)
```



```
kernel_size = inputs.squeeze(dim=0).squeeze(dim=0).size()
kernel_size
```

```
torch.Size([2, 2])
```

```
conv = torch.nn.Conv2d(in_channels=1,
                       out_channels=2,
                       kernel_size=kernel_size)
```

```
print(conv.weight.size())
```

```
print(conv.bias.size())
```

```
torch.Size([2, 1, 2, 2])
```

```
torch.Size([2])
```

```
# use same values as before
```

```
conv.weight.data = weights.view(2, 1, 2, 2)
```


```
conv.bias.data = bias
```

```
torch.relu(conv(inputs))
```


```
tensor([[[[14.9000],
```

```
         [[19.0000]]]], grad_fn=<ReluBackward0>)
```



# Es posible reemplazar capas completamente conectadas por capas convolucionales



Fully connected layer



O bien, podemos concatenar las entradas en imágenes 1x1 con 4 canales y luego usar 2 núcleos (recuerde, cada núcleo también tiene 4 canales)



```
import torch
```

Assume we have a 2x2 input image:

```
inputs = torch.tensor([[[[1., 2.],
                          [3., 4.]]]])
```

```
inputs.shape
```

```
torch.Size([1, 1, 2, 2])
```

```
fc = torch.nn.Linear(4, 2)
```

```
weights = torch.tensor([[1.1, 1.2, 1.3, 1.4],
                        [1.5, 1.6, 1.7, 1.8]])
bias = torch.tensor([1.9, 2.0])
fc.weight.data = weights
fc.bias.data = bias
```


```
torch.relu(fc(inputs.view(-1, 4)))
```

```
tensor([[14.9000, 19.0000]], grad_fn=<ReluBackward0>)
```


```
conv = torch.nn.Conv2d(in_channels=4,
                       out_channels=2,
                       kernel_size=(1, 1))
```

```
conv.weight.data = weights.view(2, 4, 1, 1)
conv.bias.data = bias
torch.relu(conv(inputs.view(1, 4, 1, 1)))
```

```
tensor([[[[14.9000]],
          [[19.0000]]]], grad_fn=<ReluBackward0>)
```



```
torch.nn.BatchNorm2d(64),  
torch.nn.ReLU(inplace=True),  
torch.nn.Conv2d(in_channels=64,  
                out_channels=num_classes,  
                kernel_size=(3, 3),  
                stride=(1, 1),  
                padding=1,  
                bias=False),  
torch.nn.BatchNorm2d(10),  
torch.nn.ReLU(inplace=True),  
# Old:  
# torch.nn.AdaptiveAvgPool2d(1),  
# New:  
torch.nn.Conv2d(in_channels=num_classes,  
                out_channels=num_classes,  
                kernel_size=(8, 8),  
                stride=(1, 1)),  
torch.nn.Flatten()
```



```

torch.nn.BatchNorm2d(64),
torch.nn.ReLU(inplace=True),
torch.nn.Conv2d(in_channels=64,
                out_channels=64,
                kernel_size=(3, 3),
                stride=(1, 1),
                padding=1,
                bias=False),
torch.nn.BatchNorm2d(64),
torch.nn.ReLU(inplace=True),
torch.Flatten(),
torch.nn.Linear(in_features=8*8*64,
                out_features=num_classes)

```

$\Leftrightarrow$

```

torch.nn.BatchNorm2d(64),
torch.nn.ReLU(inplace=True),
torch.nn.Conv2d(in_channels=64,
                out_channels=64,
                kernel_size=(3, 3),
                stride=(1, 1),
                padding=1,
                bias=False),
torch.nn.BatchNorm2d(64),
torch.nn.ReLU(inplace=True),
torch.nn.Conv2d(in_channels=64,
                out_channels=num_classes,
                kernel_size=(8, 8),
                stride=(1, 1)),
torch.nn.Flatten()

```



# ¿Se pueden enseñar trucos nuevos a un perro viejo?

- Padding (controla el tamaño de la salida junto con stride)
- Dropout 2D y batchnorm
- Arquitecturas comunes
  - VGG16 (simple, CNN profunda)
  - ResNet y skip connections
- Reemplazando Max-Pooling con capas convolucionales
- Capas convolucionales en lugar de completamente conectadas
- **Transfer learning**

# Transferir aprendizaje

- Una técnica que puede ser útil para sus proyectos de clase.
- Idea clave:
  - \* Las capas de extracción de características pueden ser útiles en general
  - \* Utilice un modelo previamente entrenado (por ejemplo, previamente entrenado en ImageNet)
  - \* Congelar los pesos: Solo entrene la última capa (o las últimas capas)
- Enfoque relacionado: Ajuste, entrene una red previamente entrenada en su conjunto de datos más pequeño

# ¿Qué capas reemplazar y entrenar?

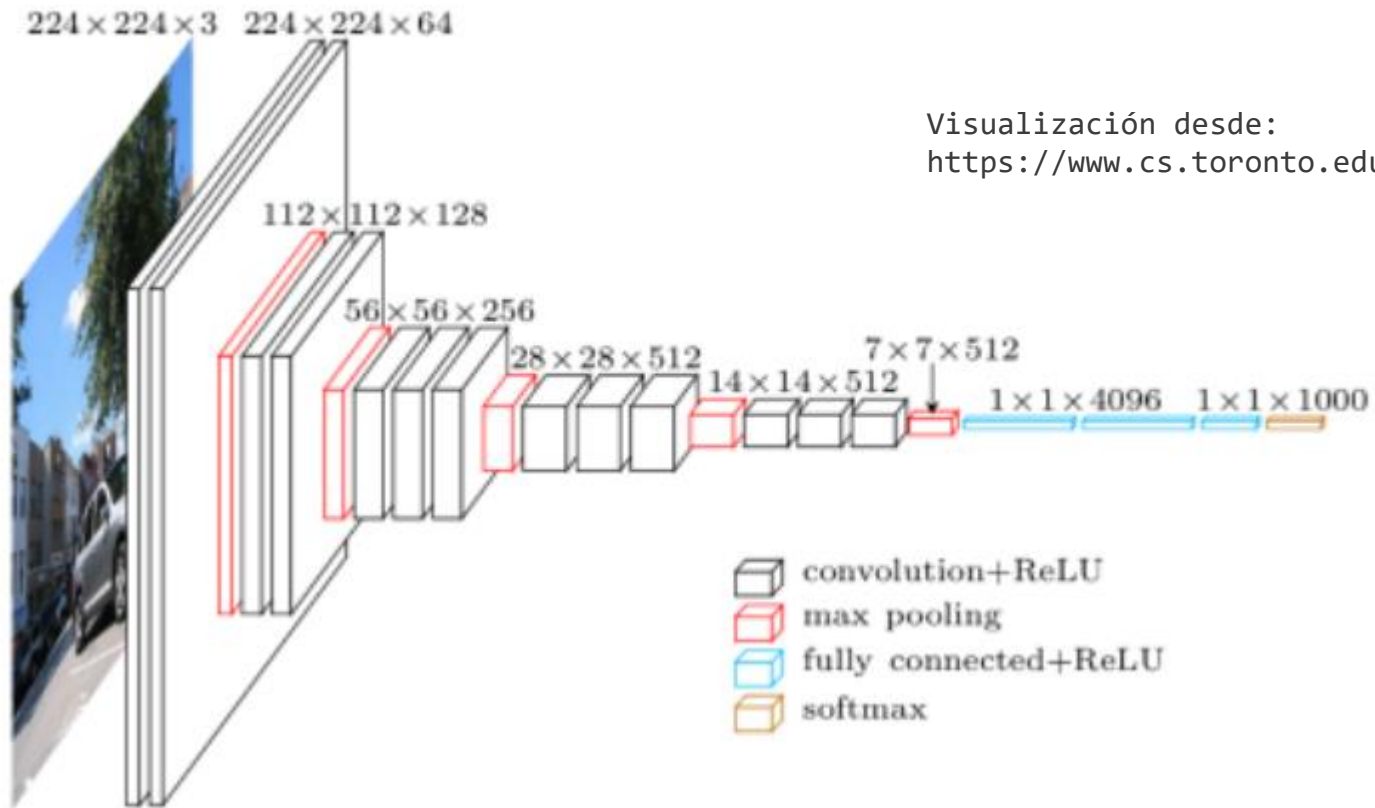
Karpathy, A., Toderici, G., Shetty, S., Leung, T., Sukthankar, R., & Fei-Fei, L. (2014). Large-scale video classification with convolutional neural networks. In Proceedings of the IEEE conference on Computer Vision and Pattern Recognition (pp. 1725-1732).

<https://cs.stanford.edu/people/karpathy/deepvideo/>

<b>Model</b>	<b>3-fold Accuracy</b>
Soomro et al [22]	43.9%
Feature Histograms + Neural Net	59.0%
Train from scratch	41.3%
Fine-tune top layer	64.1%
Fine-tune top 3 layers	<b>65.4%</b>
Fine-tune all layers	62.2%

Table 3: Results on UCF-101 for various Transfer Learning approaches using the Slow Fusion network.


# Transfer learning



Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).

<https://arxiv.org/abs/1409.1556>

# Transferir aprendizaje



Simonyan, Karen, and Andrew Zisserman. "[Very deep convolutional networks for large-scale image recognition](#)." *arXiv preprint arXiv:1409.1556* (2014).

# Transfer learning

<https://pytorch.org/docs/stable/torchvision/models.html>

## TORCHVISION.MODELS

The models subpackage contains definitions of models for addressing different tasks, including: image classification, pixelwise semantic segmentation, object detection, instance segmentation, person keypoint detection and video classification.

### Classification

The models subpackage contains definitions for the following model architectures for image classification:

- AlexNet
- VGG
- ResNet
- SqueezeNet
- DenseNet
- Inception v3
- GoogLeNet
- ShuffleNet v2
- MobileNet v2
- ResNeXt
- Wide ResNet
- MNASNet



Código de ejemplo de  
transfer learning