Lecture08
Redes Neuronales Convolucionales para detección de objetos y segmentación semántica

CNNs para Visión por Computador

[Krizhevsky 2012]

[Ciresan et al. 2013]

[Faster R-CNN - Ren 2015]

[NVIDIA dev blog]

Más allá de la clasificación de imágenes

CNNs

- Conferencia anterior: clasificación de imágenes.

Limitaciones

- Principalmente en imágenes centradas
- Solo un objeto por imagen
- No es suficiente para muchas tareas de visión del mundo real

Más allá de la clasificación de imágenes

Classification

single object

Más allá de la clasificación de imágenes

Más allá de la clasificación de imágenes

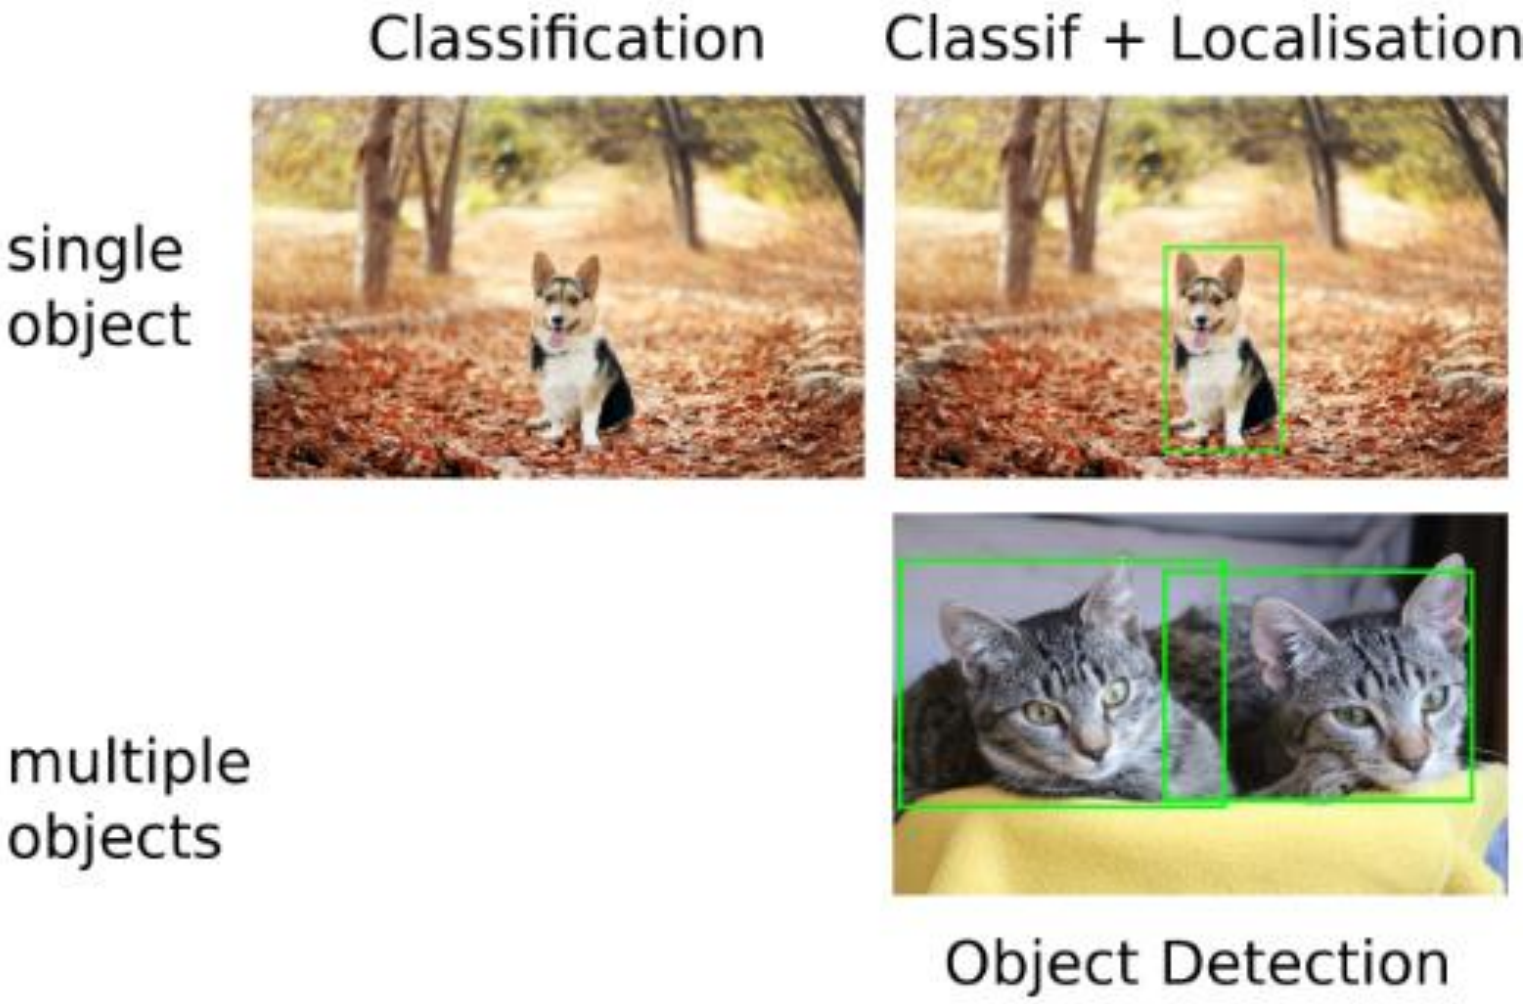

Más allá de la clasificación de imágenes

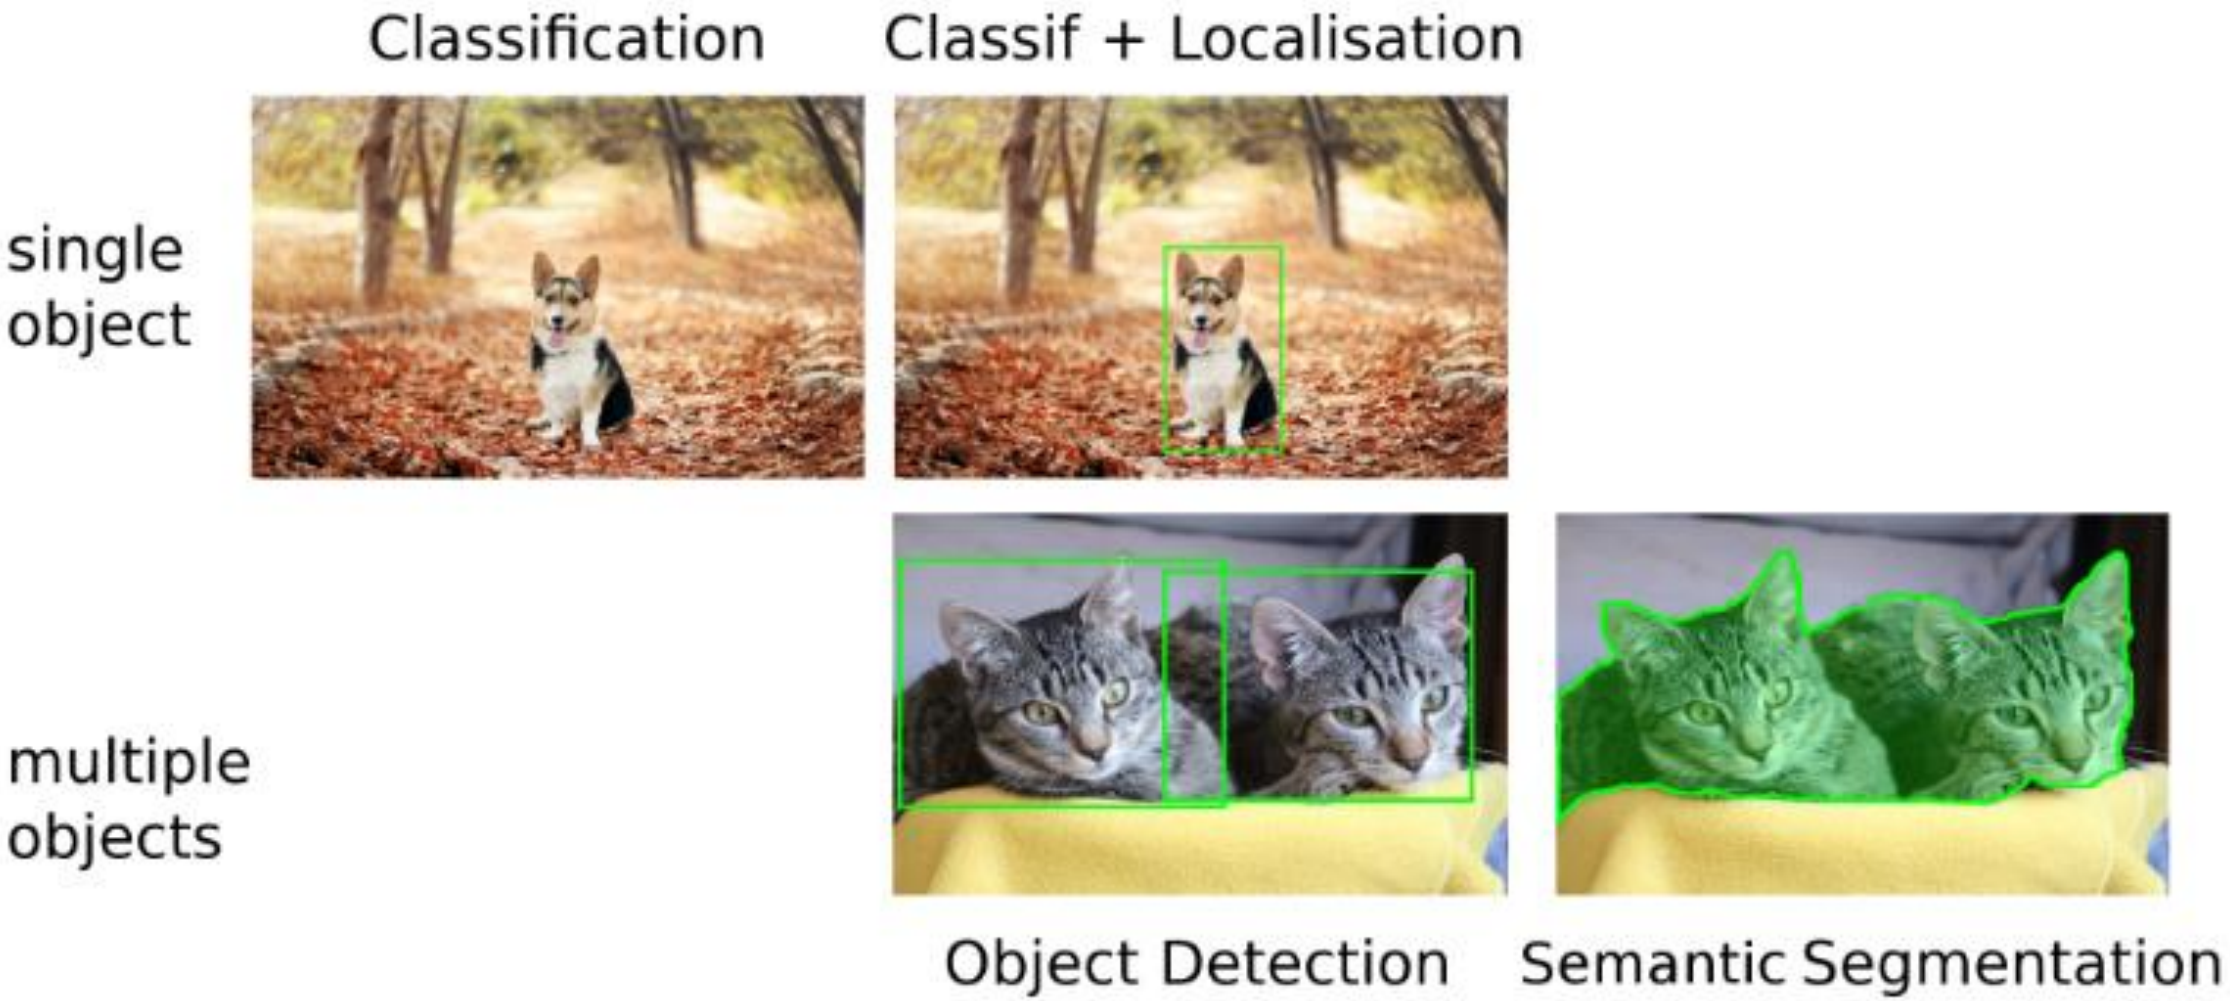

Más allá de la clasificación de imágenes

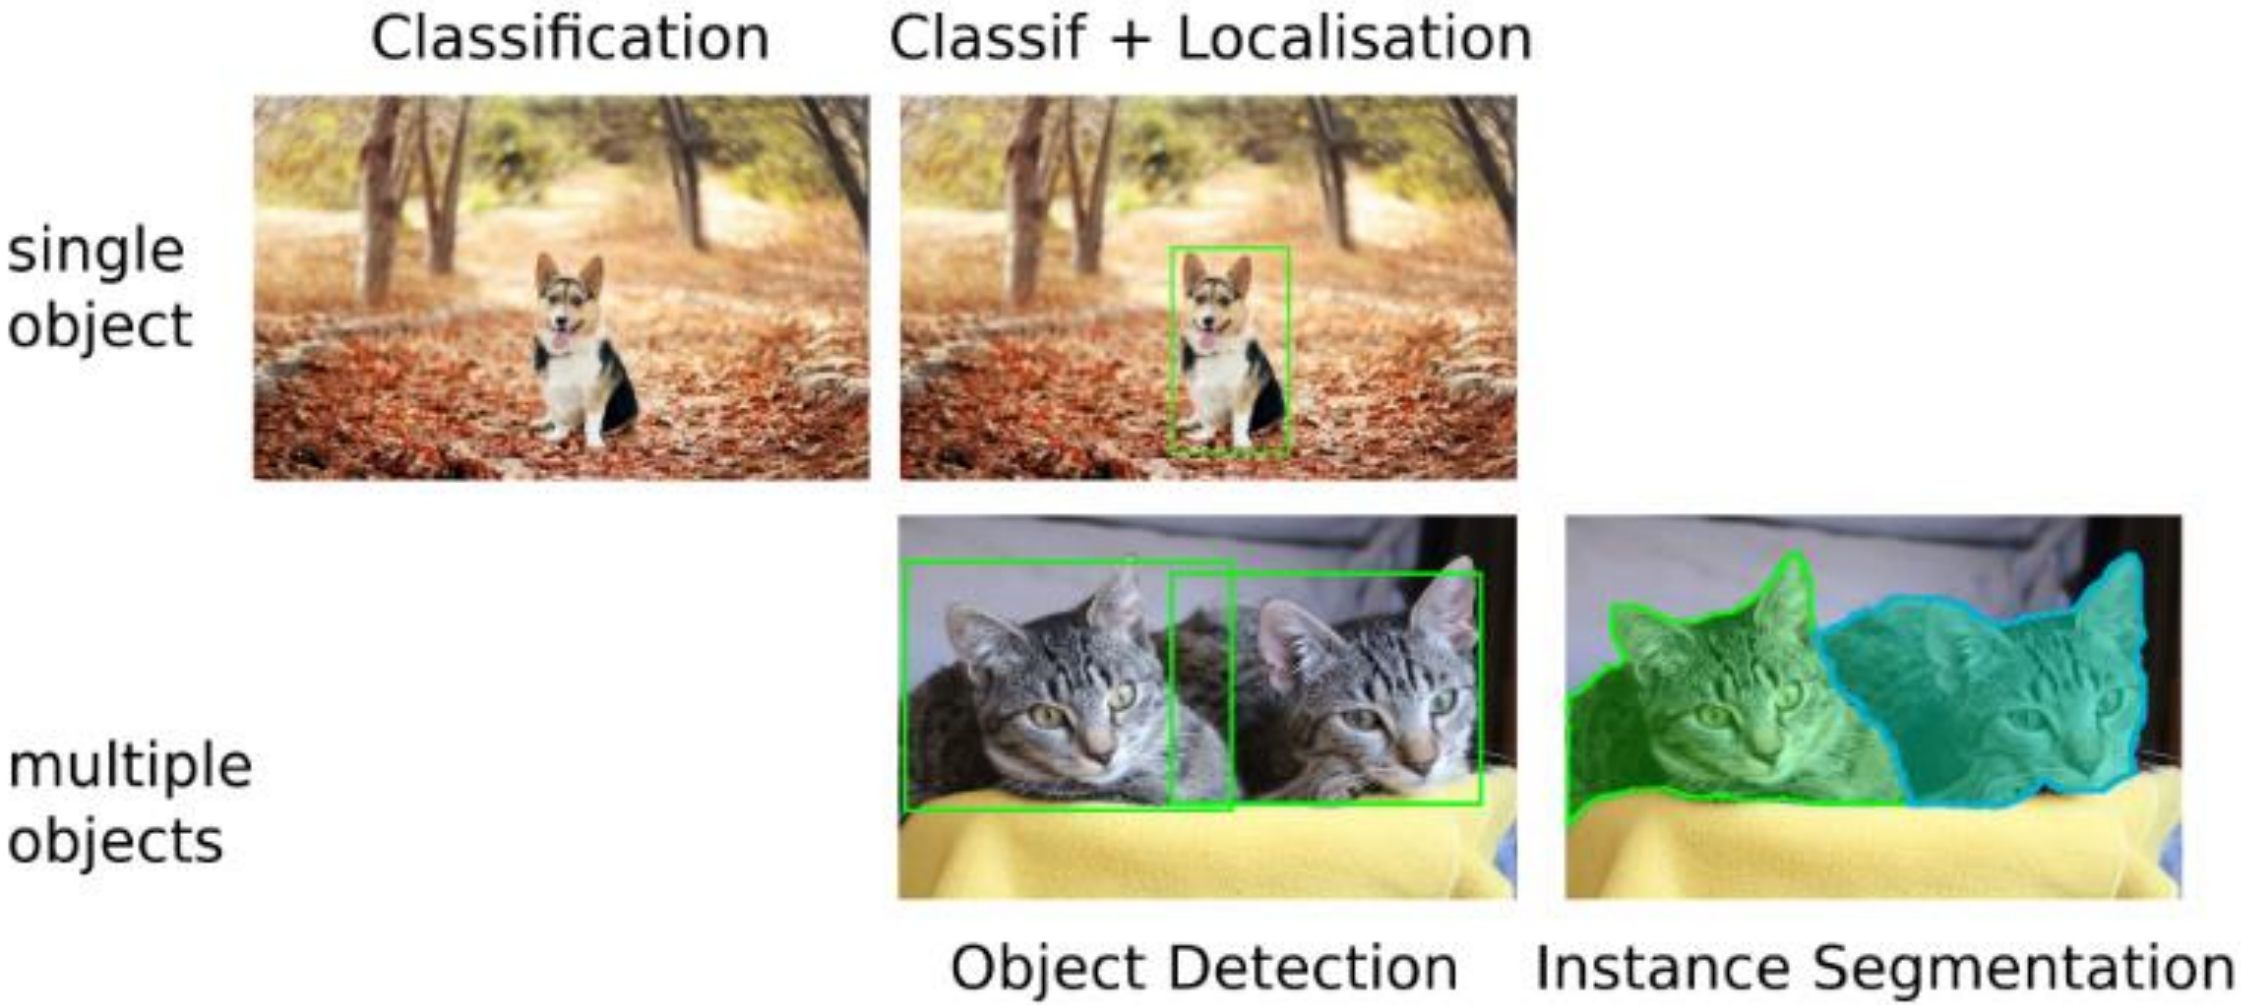

Esquema

Localización simple como regresión

Algoritmos de detección

Redes completamente convolucionales

Segmentación semántica y de instancias

Localización

Localización

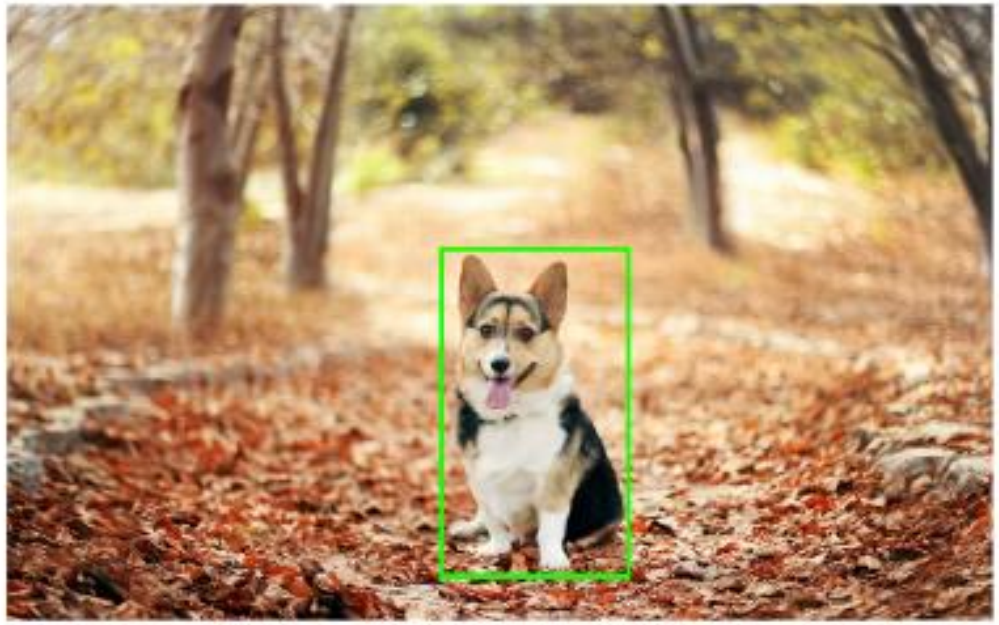

- Un solo objeto por imagen
- Predecir las coordenadas de una caja delimitadora (x, y, w, h)
- Evaluar mediante la intersección sobre unión (IoU)

Localización como regresión

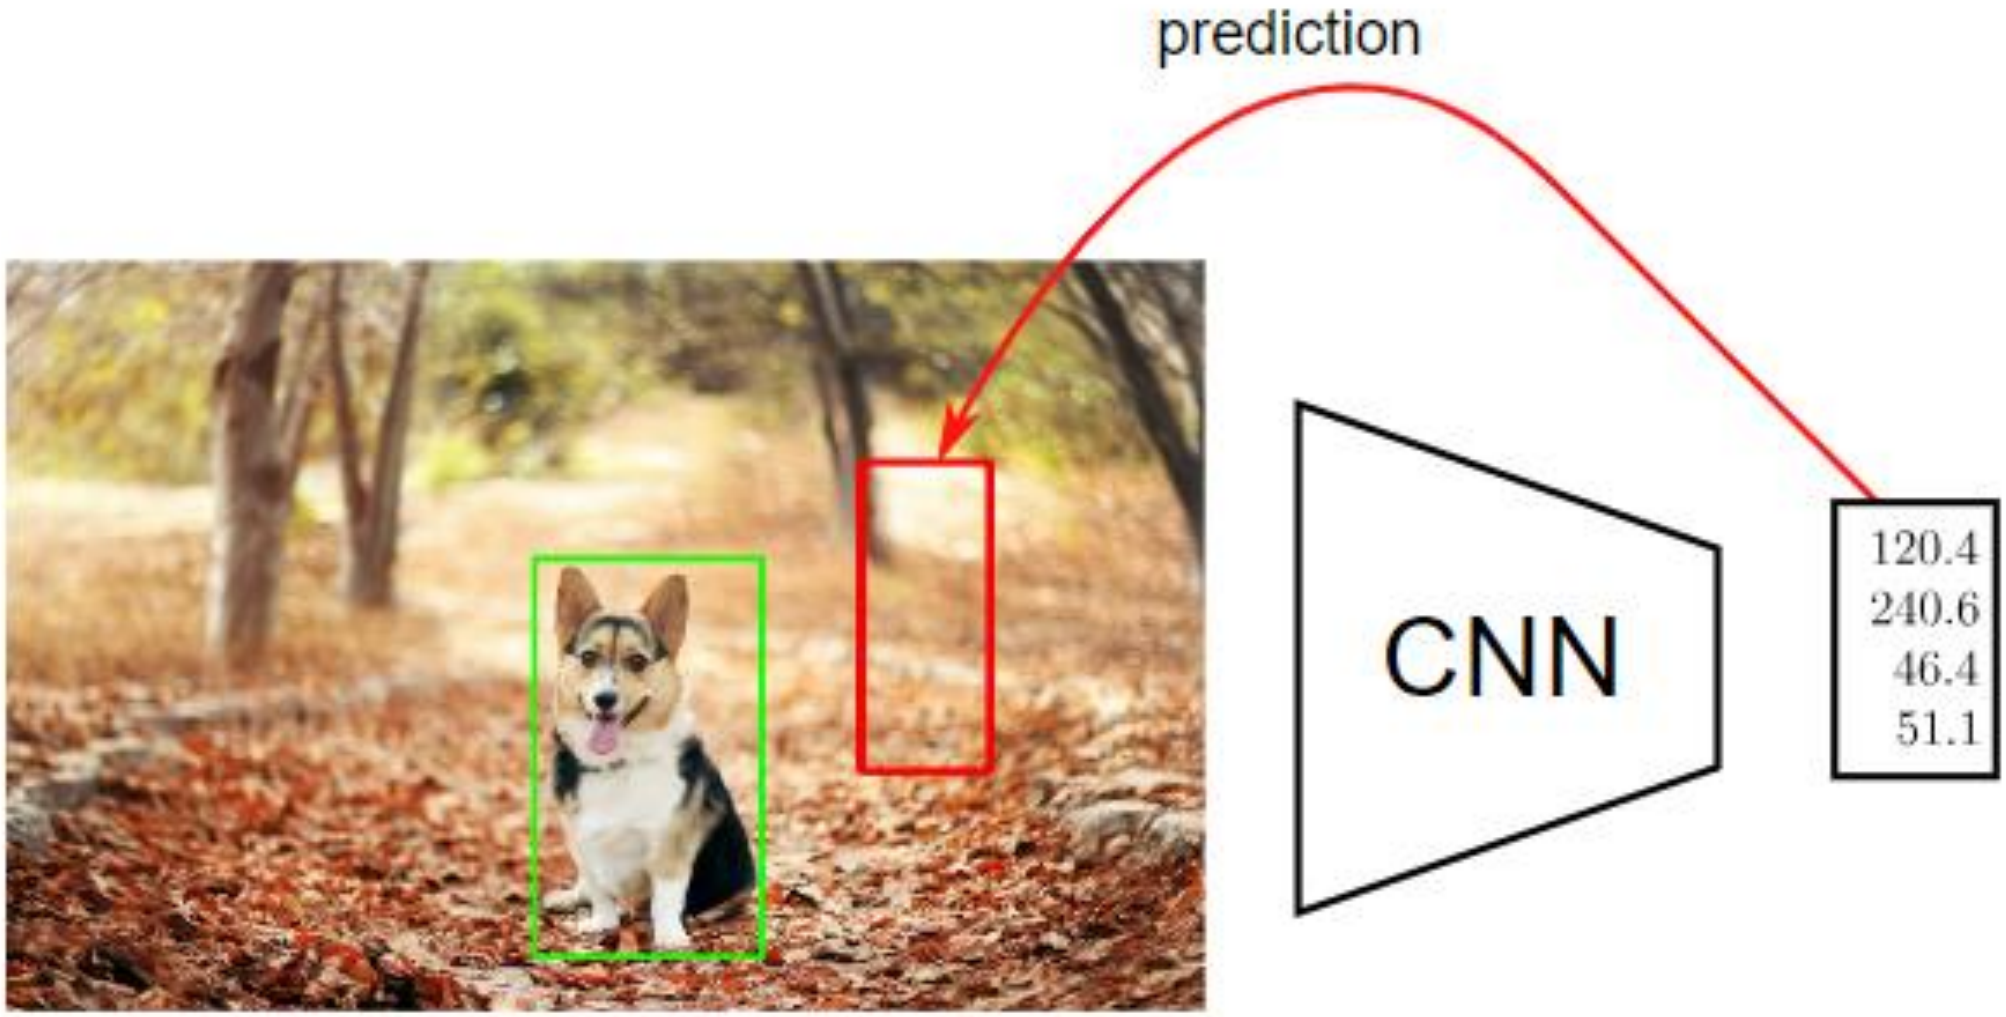

Localización como regresión

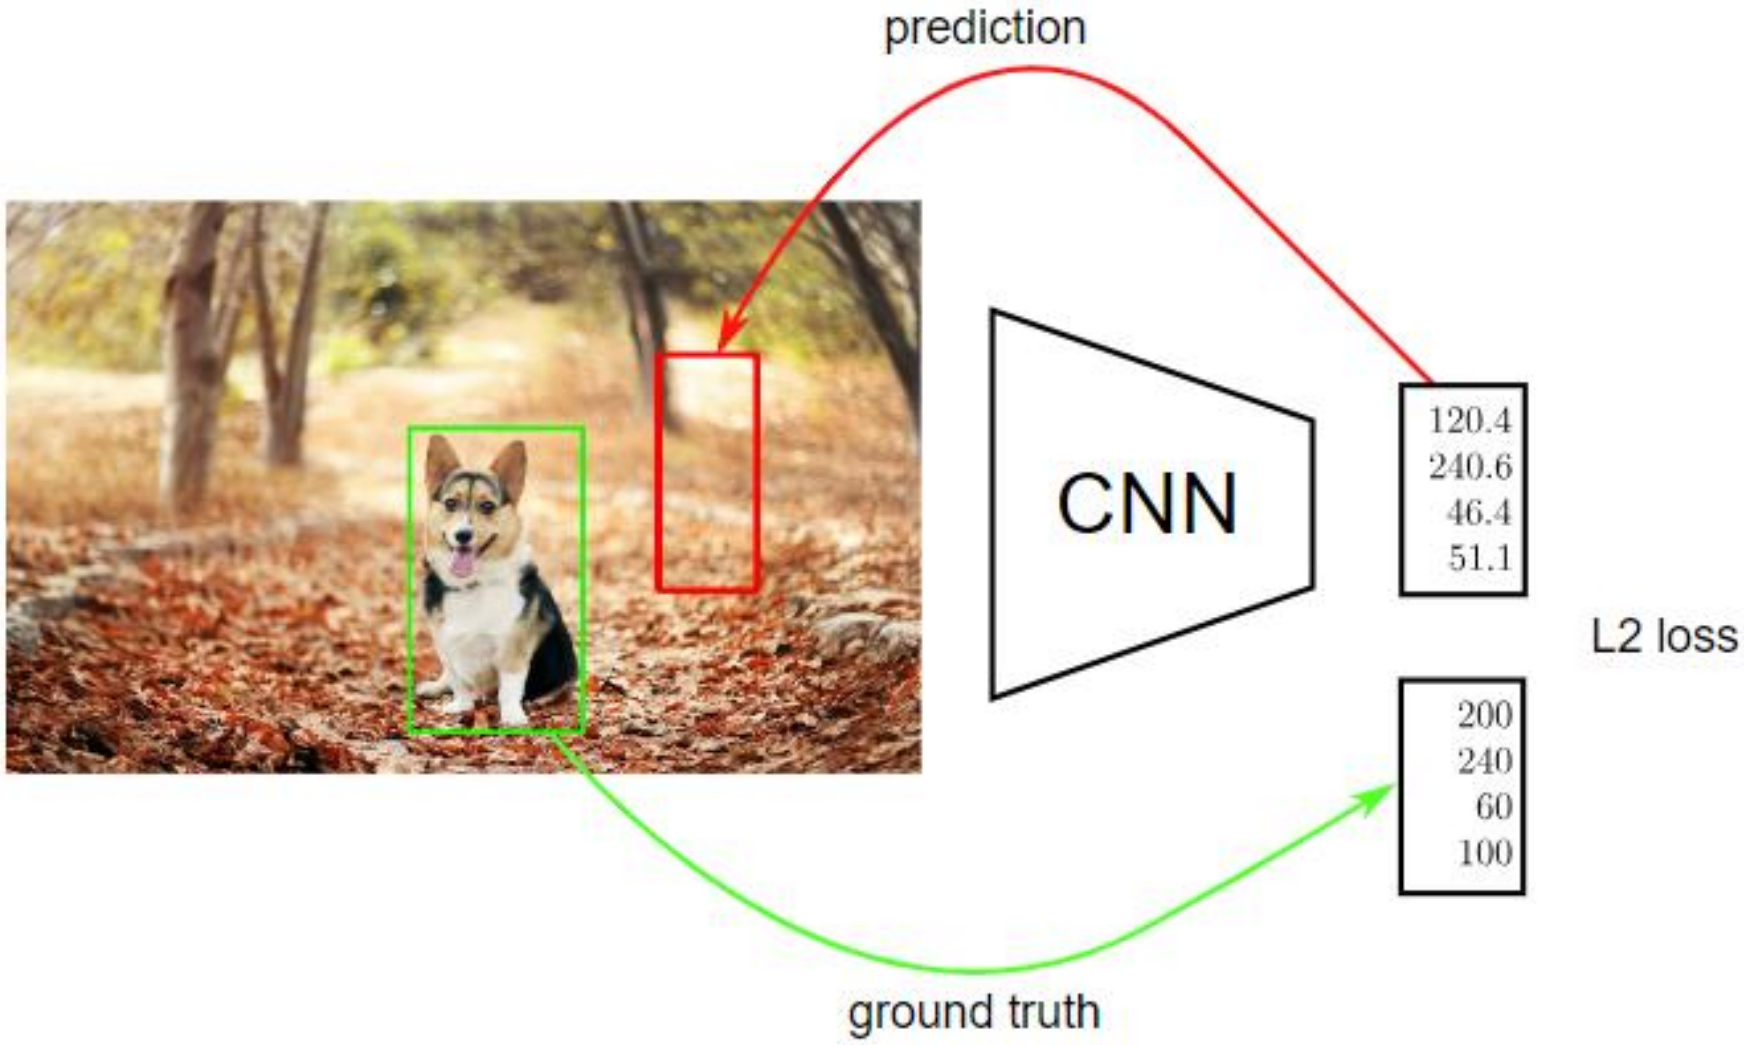

Clasificación + Localización

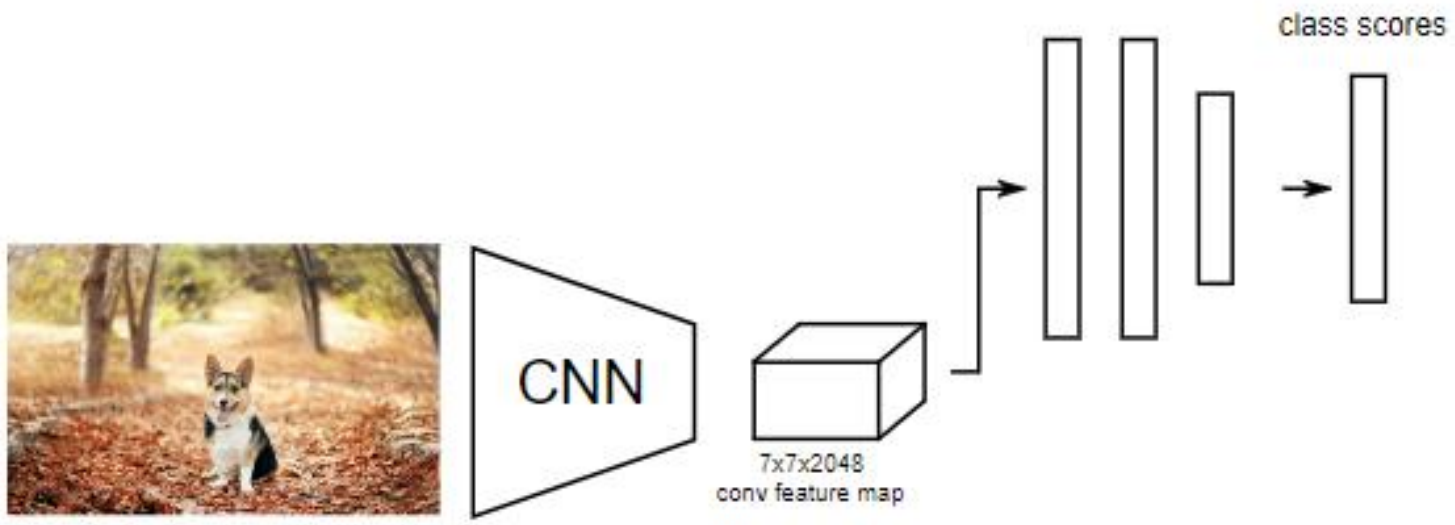

Clasificación + Localización

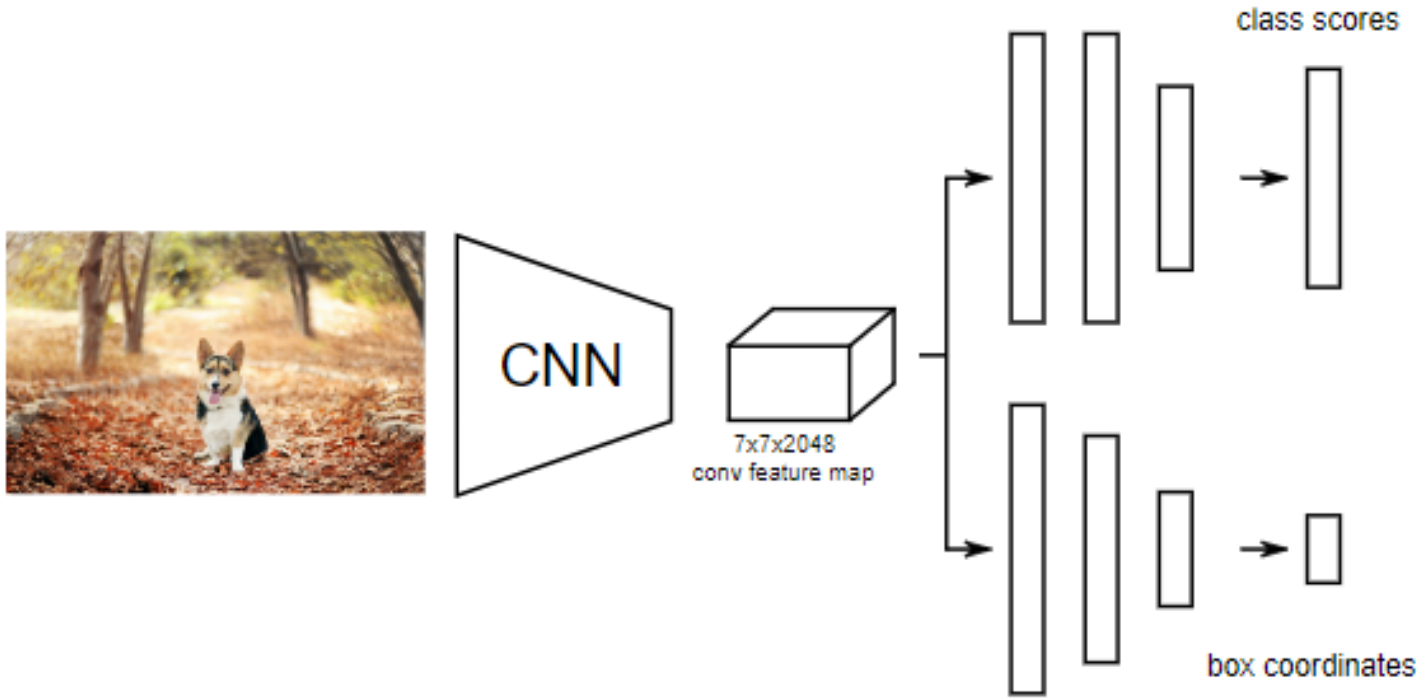

Clasificación + Localización

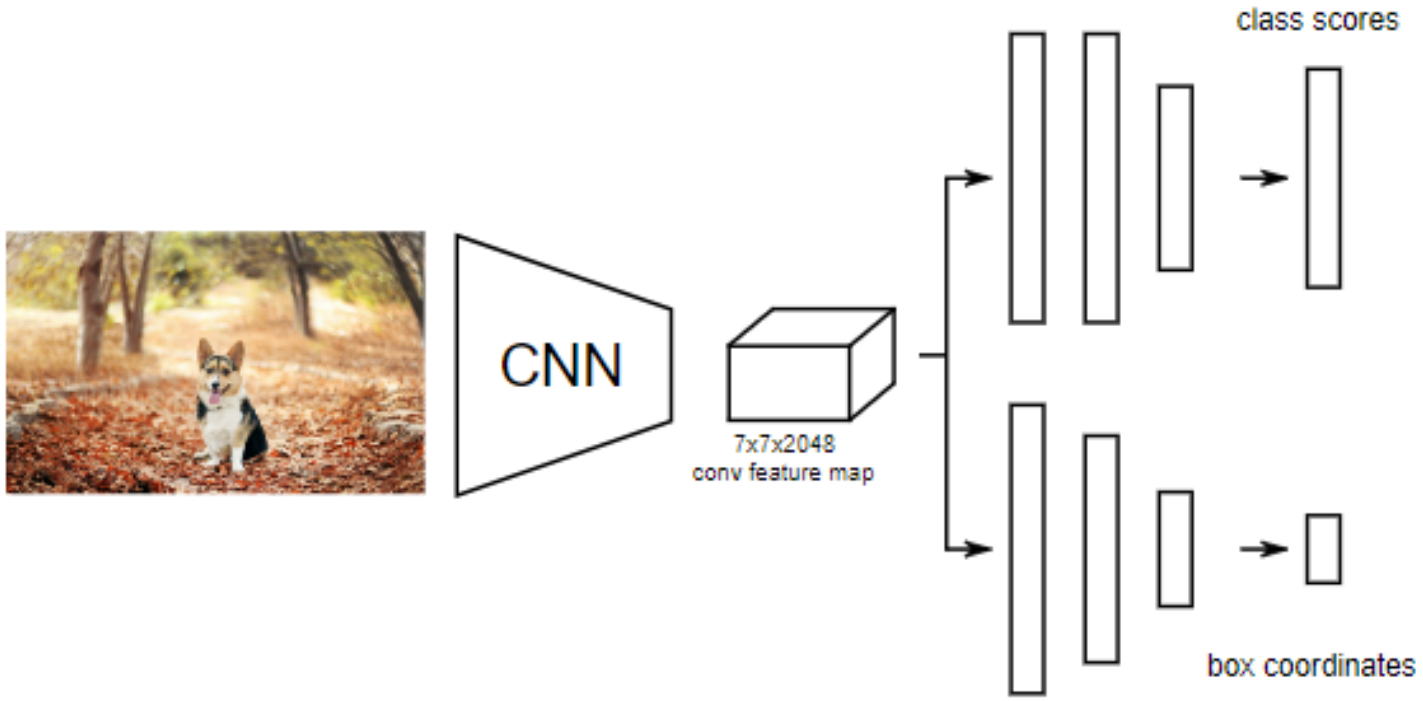

- Utiliza una CNN preentrenada en ImageNet (ej. ResNet)
- La "cabeza de localización" se entrena por separado con regresión
- Posible ajuste fino de extremo a extremo para ambas tareas
- En la fase de prueba, se usan ambas cabezas

Clasificación + Localización

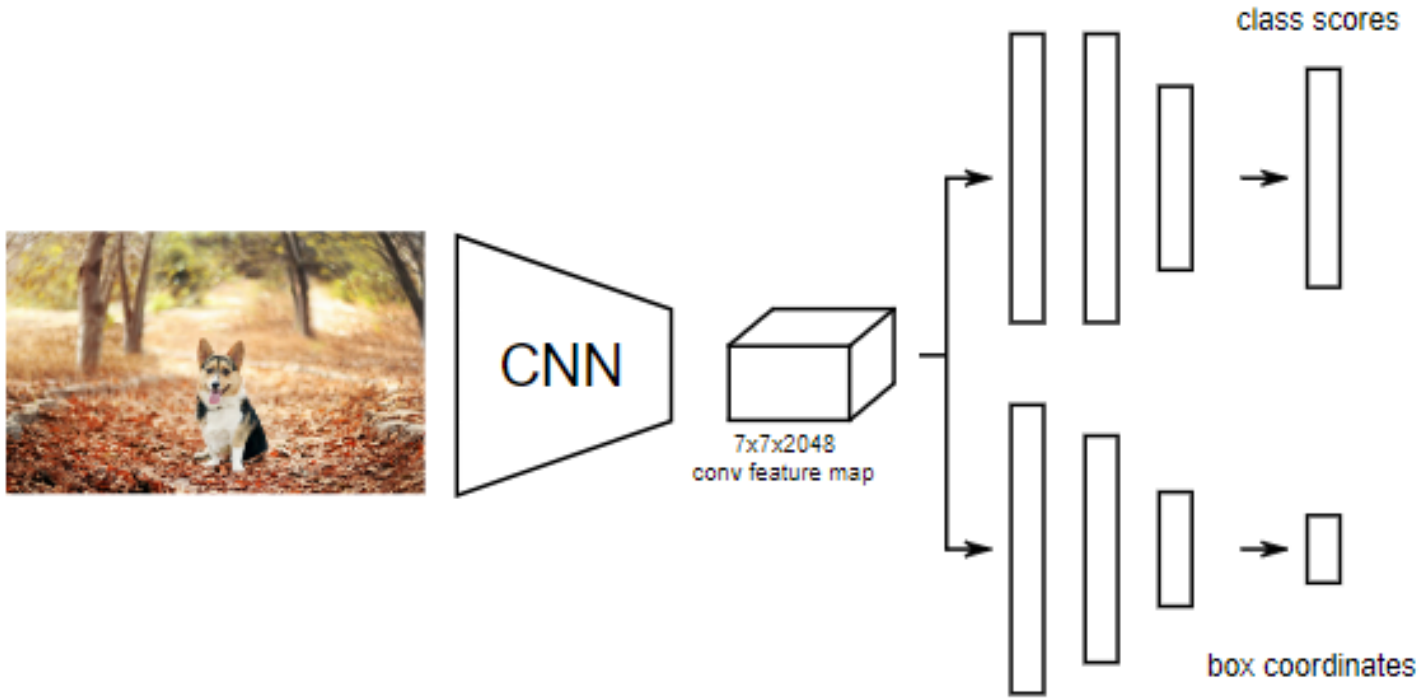

C clases, 4 dimensiones de salida (1 caja)

Predecir exactamente N objetos: predecir las coordenadas ($N \times 4$) y las puntuaciones de clase ($N \times K$)

Detección de objetos

No sabemos de antemano la cantidad de objetos en la imagen. La detección de objetos se basa en la *propuesta de objetos* y la *clasificación de objetos*

Propuesta de objetos: encontrar regiones de interés (RoIs) en la imagen.

Clasificación de objetos: clasificar el objeto en esas regiones.

Dos familias principales:

- Single-Stage: Una cuadrícula en la imagen donde cada celda es una propuesta (SSD, YOLO, RetinaNet).
- Two-Stage: Propuesta de región y luego clasificación (Faster-RCNN).

YOLO

$S \times S$ grid on input

Para cada celda de la cuadrícula $S \times S$ predecir:

- B **cajas delimitadoras** y **puntuaciones de confianza** C ($5 \times B$ valores) + **clases** C

Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." CVPR (2016)

YOLO

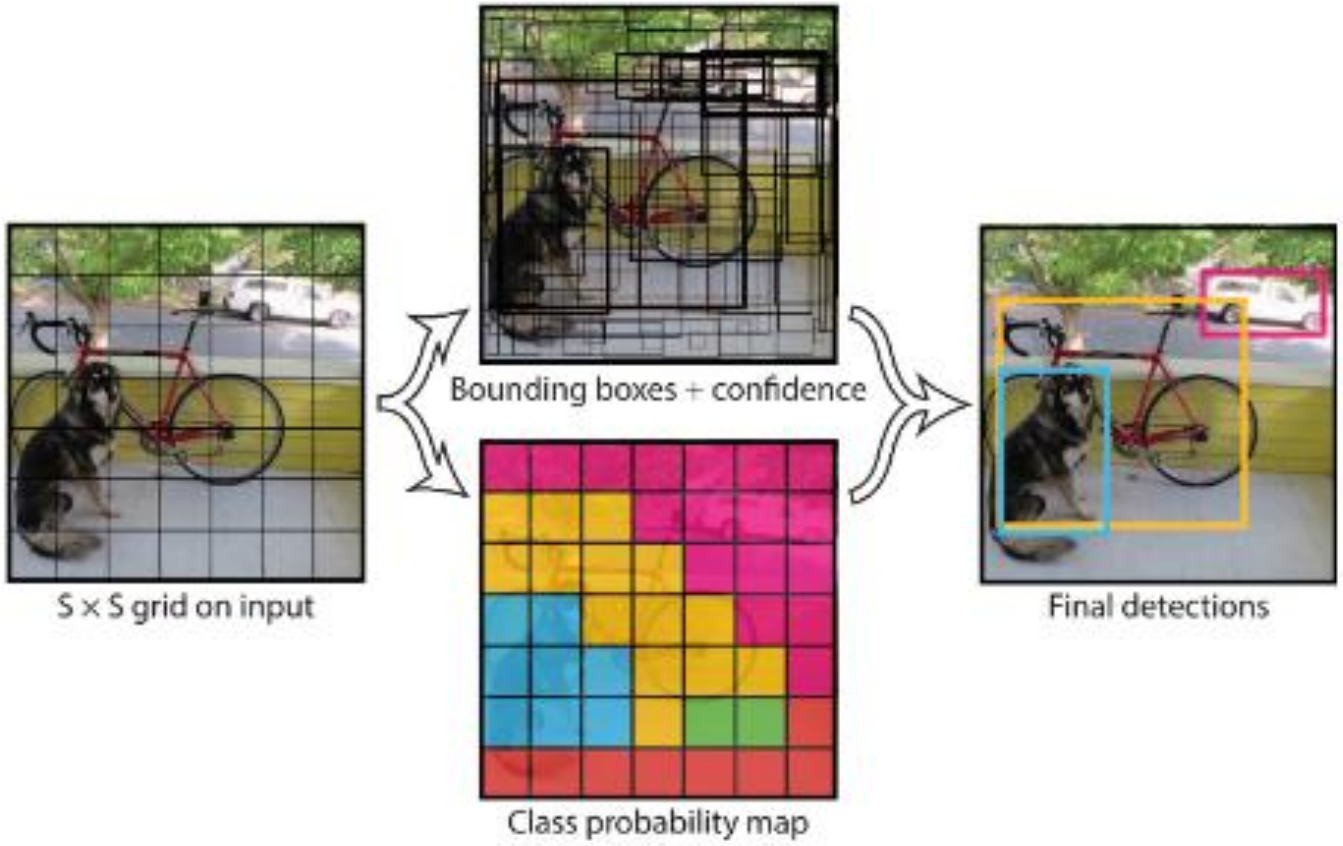

Para cada celda de la cuadrícula $S \times S$ predecir:

- B **cajas delimitadoras** y **puntuaciones de confianza** C ($5 \times B$ valores) + **clases** C

Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." CVPR (2016)

YOLO

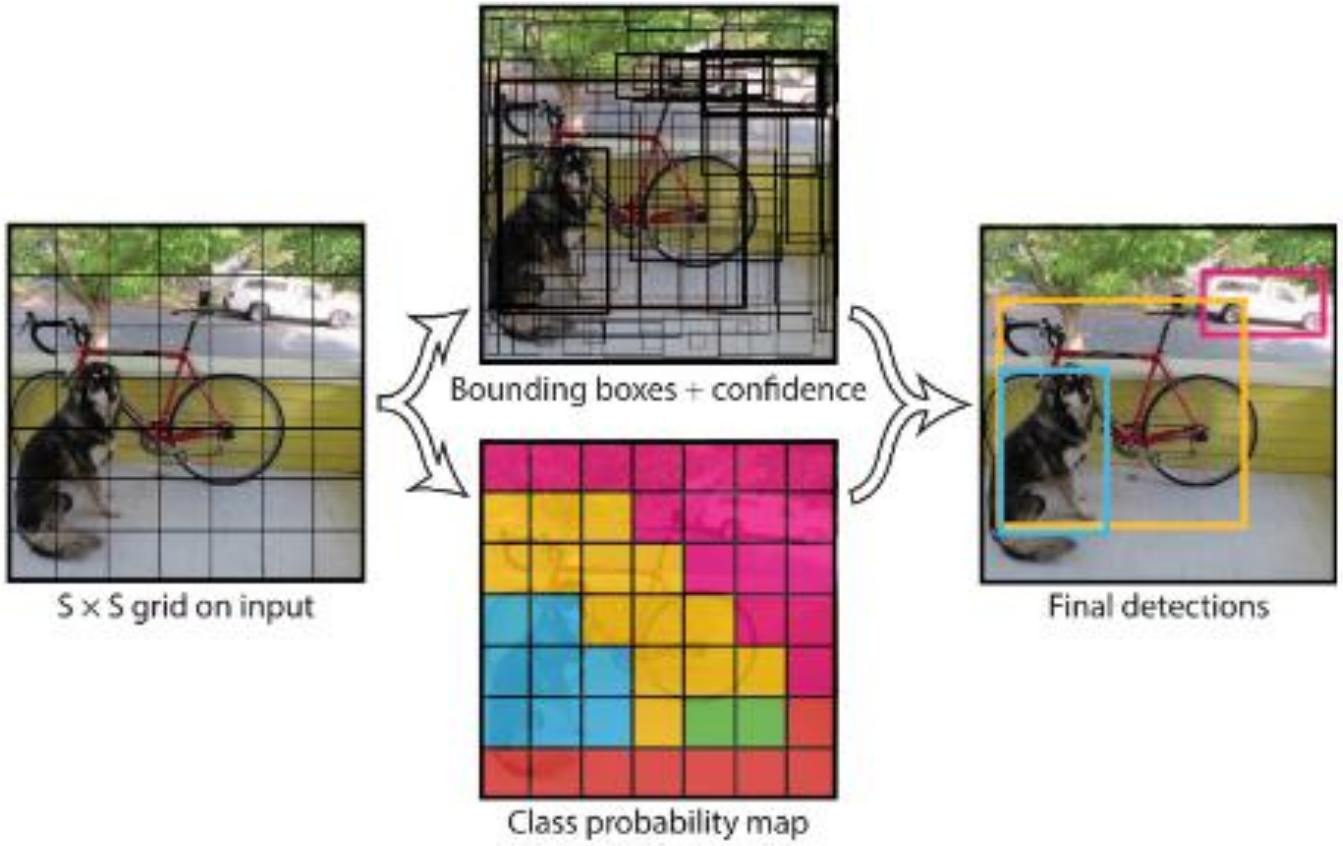

Detecciones finales: Cj * prob(c) > umbral

Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." CVPR (2016)

YOLO

- Después del preentrenamiento en ImageNet, toda la red se entrena de extremo a extremo.

- La pérdida es una suma ponderada de diferentes regresiones.

$$
\begin{aligned}
&\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbf{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\
&+ \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbf{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\
&+ \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbf{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\
&+ \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbf{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\
&+ \sum_{i=0}^{S^2} \mathbf{1}_{ij}^{\text{obj}} \sum_{c \in \text{Classes}} (p_i(c) - \hat{p}_i(c))^2
\end{aligned}
$$

Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." CVPR (2016)

RetinaNet

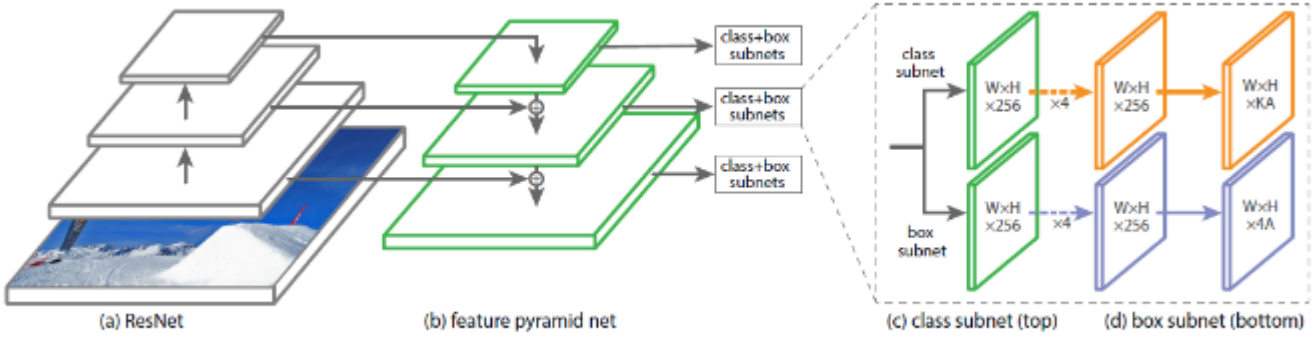

- Detector de una sola etapa con:

- Múltiples escalas a través de una *Red Piramidal de Características (Feature Pyramid Network)*
- Pérdida focal (Focal Loss) para gestionar el desequilibrio entre el fondo y los objetos reales

- Consulta este link para más información.

Lin, Tsung-Yi, et al. "Focal loss for dense object detection." ICCV 2017

Propuestas de Cajas

En lugar de tener un conjunto predefinido de propuestas de cajas, encuéntralas en la imagen:

- **Selective Search**: a partir de píxeles (no aprendido, ya no se usa).
- **Faster-RCNN:** Red de Propuestas de Regiones (RPN).

Operador de recorte y redimensionamiento (RoI-Pooling):

- Entrada: mapa convolucional + N regiones de interés.
- Salida: tensor de $N \times 7 \times 7 \times profundidad$ de las cajas.
- Permite propagar el gradiente solo en las regiones de interés, y facilita el cálculo eficiente.

Girshick, Ross, et al. "Fast r-cnn." ICCV 2015

Faster - RCNN

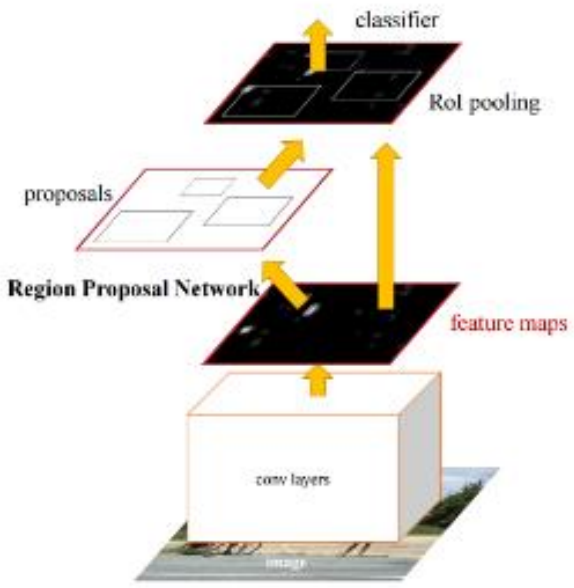

- Entrenar conjuntamente la **RPN** y la otra cabeza
- 200 propuestas de cajas, el gradiente se propaga solo en las cajas positivas
- La propuesta de región es invariante a la traslación, en comparación con YOLO

Ren, Shaoqing, et al. "Faster r-cnn: Towards real-time object detection with region proposal networks." NIPS 2015

Medición del rendimiento

method	test size shorter edge/max size	feature pyramid	align	mAP@[0.5:0.95]	AP_s	AP_m	AP_l
R-FCN [17]	600/1000			32.1	12.8	34.9	46.1
Faster R-CNN (2fc)	600/1000			30.3	9.9	32.2	47.4
Deformable [3]	600/1000		√	34.5	14.0	37.7	50.3
G-RMI [13]	600/1000			35.6	-	-	-
FPN [19]	800/1200	√		36.2	18.2	39.0	48.2
Mask R-CNN [7]	800/1200	√	√	38.2	20.1	41.1	50.2
RetinaNet [20]	800/1200	√		37.8	20.2	41.1	49.2
RetinaNet ms-train [20]	800/1200	√		39.1	21.8	42.7	50.2
Light head R-CNN	800/1200		√	**39.5**	21.8	43.0	50.7
Light head R-CNN ms-train	800/1200		√	**40.8**	22.7	44.3	52.8
Light head R-CNN	800/1200	√	√	**41.5**	25.2	45.3	53.1

Medidas: Precisión Promedio Media **(mAP)** con umbrales dados de **IoU**

- AP @0.5 para la clase "gato": precisión promedio para la clase, donde $IoU(box^{pred}, box^{true}) > 0.5$

Zeming Li et al. Light-Head R-CNN: In Defense of Two-Stage Object Detector 2017

Estado del arte

Model	FLOPs	# Params	AP_{val}	$AP_{test\text{-}dev}$
SpineNet-190 (1536) [11]	2076B	176.2M	52.2	52.5
DetectoRS ResNeXt-101-64x4d [43]	—	—	—	55.7†
SpineNet-190 (1280) [11]	1885B	164M	52.6	52.8
SpineNet-190 (1280) w/ self-training [71]	1885B	164M	54.2	54.3
EfficientDet-D7x (1536) [56]	410B	77M	54.4	55.1
YOLOv4-P7 (1536) [60]	—	—	—	55.8†
Cascade Eff-B7 NAS-FPN (1280)	1440B	185M	54.5	54.8
w/ Copy-Paste	1440B	185M	(+1.4) **55.9**	(+1.2) **56.0**
w/ self-training Copy-Paste	1440B	185M	(+2.5) **57.0**	(+2.5) **57.3**

- Tamaños de imagen más grandes, modelos más grandes y mejores, mejores datos aumentados.
- https://paperswithcode.com/sota/object-detection-on-coco

Ghiasi G. et al. Simple Copy-Paste is a Strong Data Augmentation Method for Instance Segmentation, 2020

Otros trabajos

- Nuevos enfoques intentan evitar el uso de anclas.
- CornerNet solo predice los dos extremos de una caja:

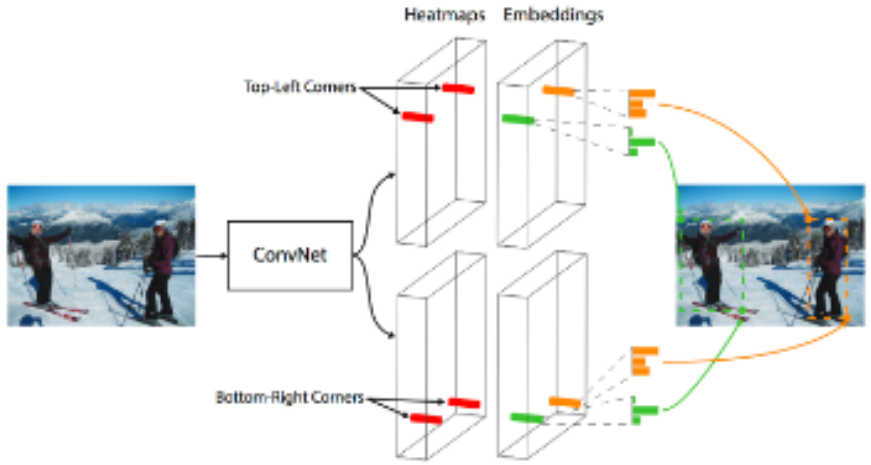

Law, Hei, and Deng, Jia. "CornerNet: Detecting Objects as Paired Keypoints" ECCV 2018

Otros trabajos

- Nuevos enfoques intentan evitar el uso de anclas.

- DeTr usa un Transformer para mapear un conjunto de características a un conjunto de cajas (con diferente cardinalidad).

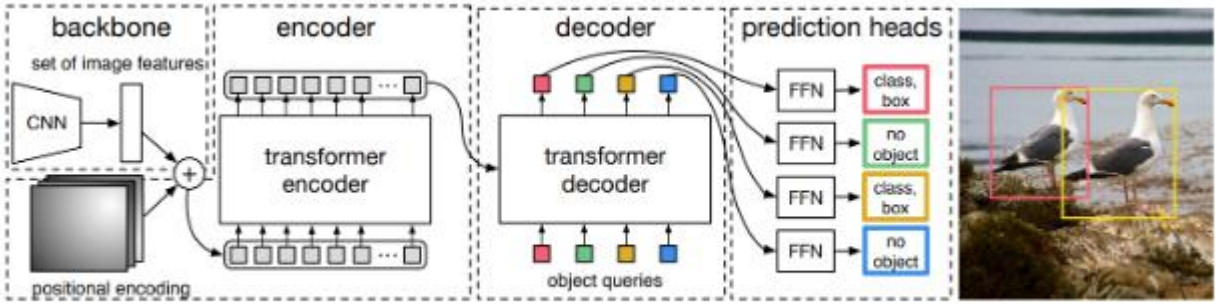

La pérdida es una coincidencia por pares entre el conjunto de verdad de terreno y el conjunto de predicciones. Esta asignación óptima se calcula con el algoritmo Húngaro.

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. "End-to-End Object Detection with Transformers" ECCV 2020

Segmentación

Segmentación

- Salida de un mapa de clases para cada píxel (aquí: perro vs fondo)

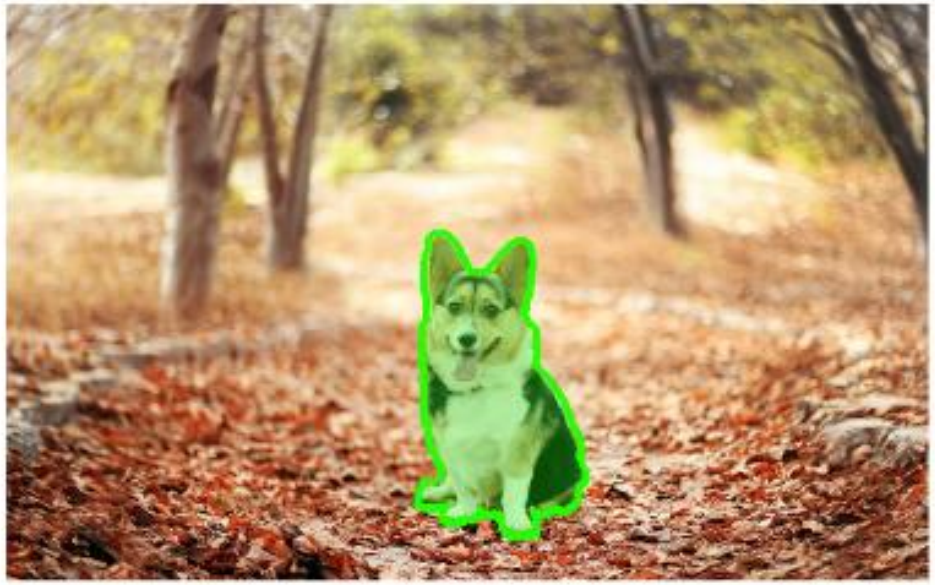

- **Segmentación de instancias**: especifica cada instancia de objeto (dos perros tienen diferentes instancias).
- Esto se puede lograr a través de **detección de objetos + segmentación.**

Convolución

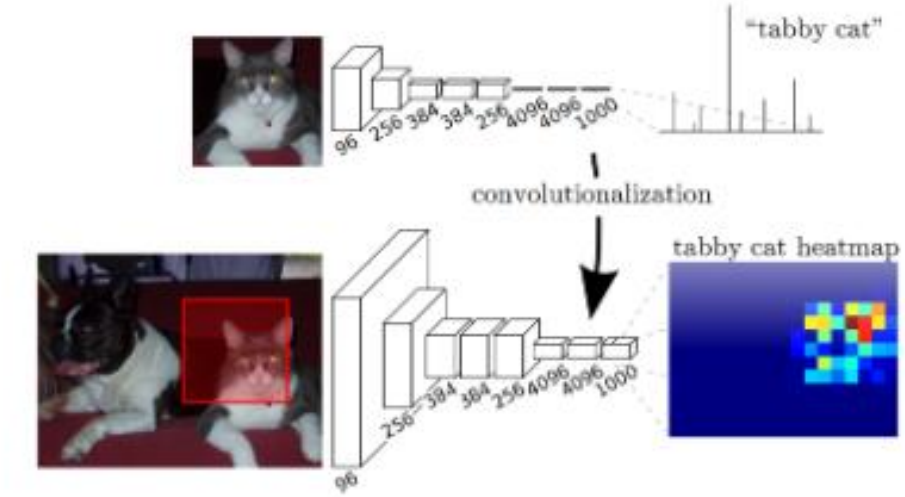

- Desliza la red con una entrada de (224, 224) sobre una imagen más grande. Salida de tamaño espacial variable.
- **Convolucionar**: cambia la capa densa (4096, 1000) a una convolución de 1 × 1, con 4096 canales de entrada y salida.
- Da una **segmentación** burda (sin supervisión adicional).

Long, Jonathan, et al. "Fully convolutional networks for semantic segmentation." CVPR 2015

Red Totalmente Convolucional

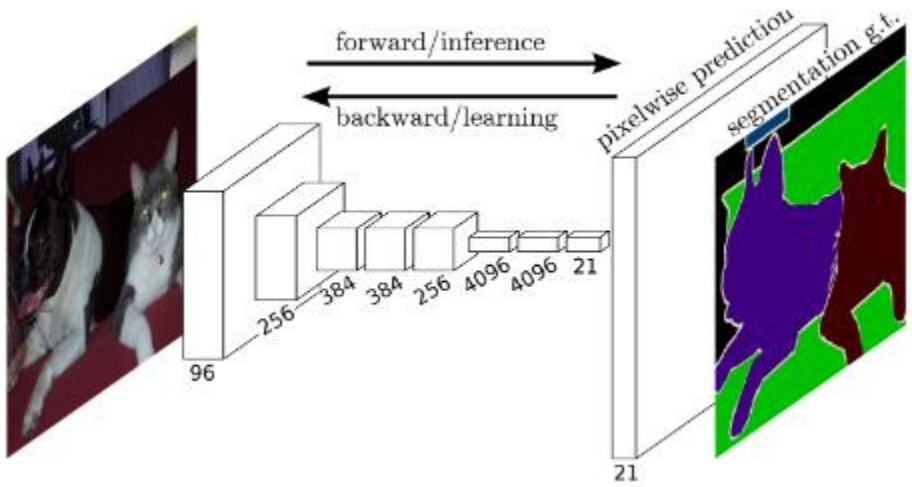

- Predecir / retropropagar por cada píxel de salida.
- Agregar mapas de varias convoluciones a diferentes escalas para obtener resultados más robustos.

Long, Jonathan, et al. "Fully convolutional networks for semantic segmentation." CVPR 2015

Deconvolución

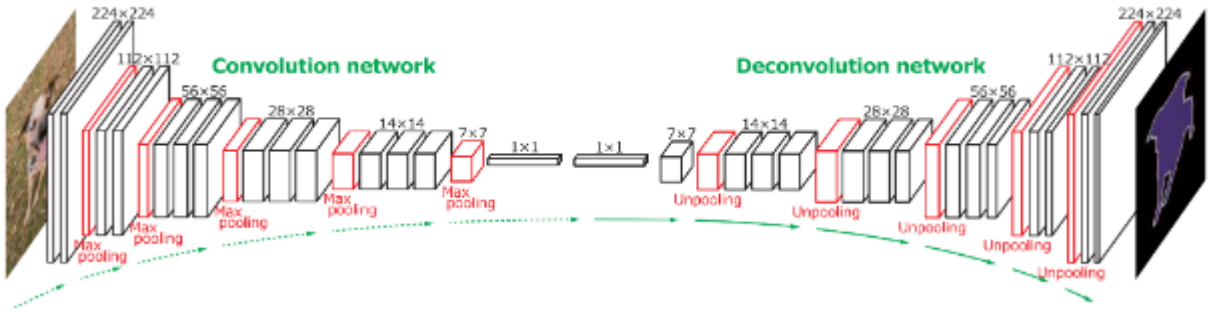

- "Deconvolución": convoluciones transpuestas

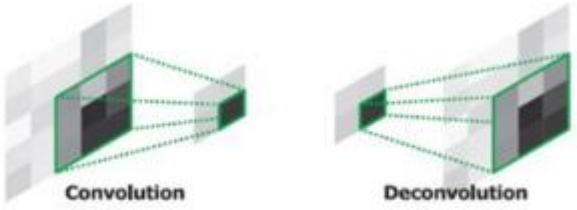

Noh, Hyeonwoo, et al. "Learning deconvolution network for semantic segmentation." ICCV 2015

Deconvolución

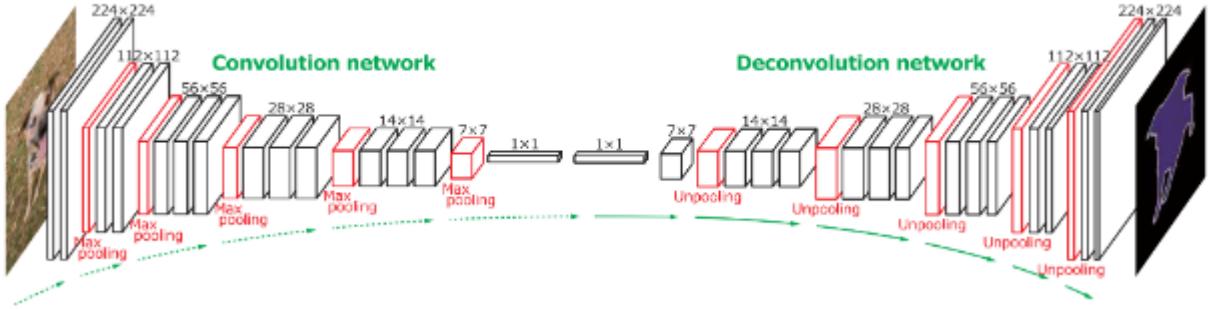

- **Conexiones de salto** entre las capas correspondientes de convolución y deconvolución.
- **Máscaras más definidas** utilizando información espacial precisa (capas tempranas).
- **Mejor detección de objetos** utilizando información semántica (capas tardías).

Noh, Hyeonwoo, et al. "Learning deconvolution network for semantic segmentation." ICCV 2015

Red Hourglass

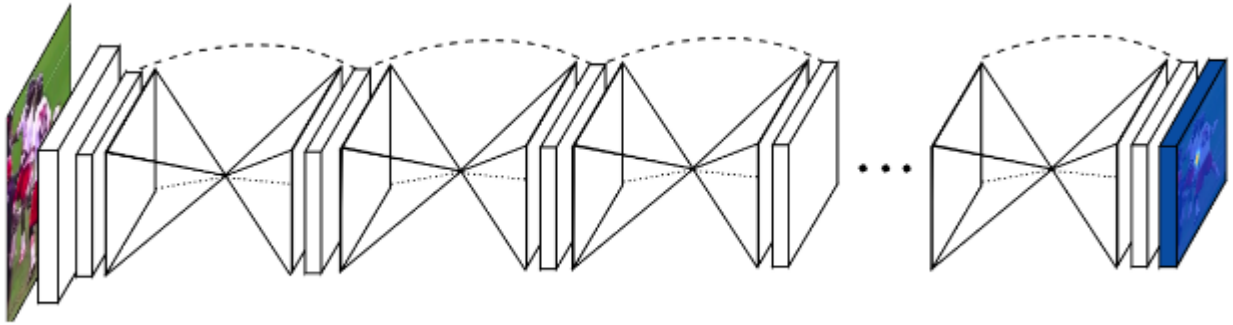

- Arquitecturas tipo U-Net repetidas secuencialmente.
- Cada bloque refina la segmentación para el siguiente.
- Cada bloque tiene una pérdida de segmentación.

Newell, Alejandro, et al. "Stacked Hourglass Networks for Human Pose Estimation." ECCV 2016

Mask-RCNN

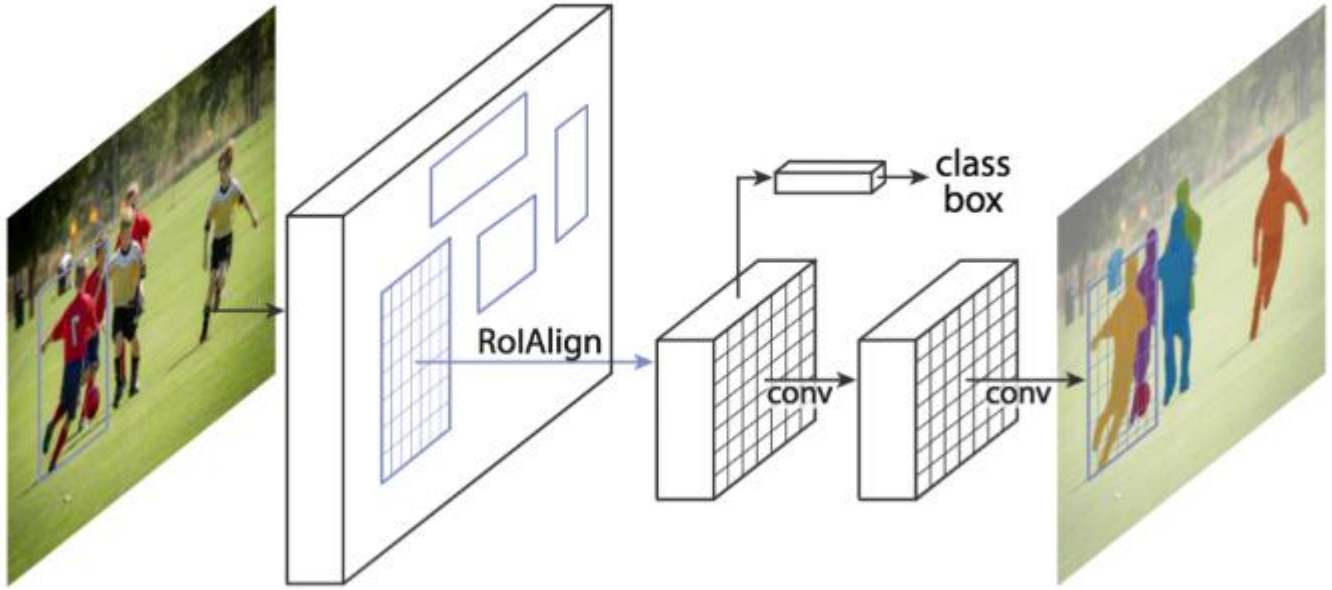

Arquitectura Faster-RCNN con una tercera cabeza de máscara binaria.

K. He and al. Mask Region-based Convolutional Network (Mask R-CNN) NIPS 2017

Resultados

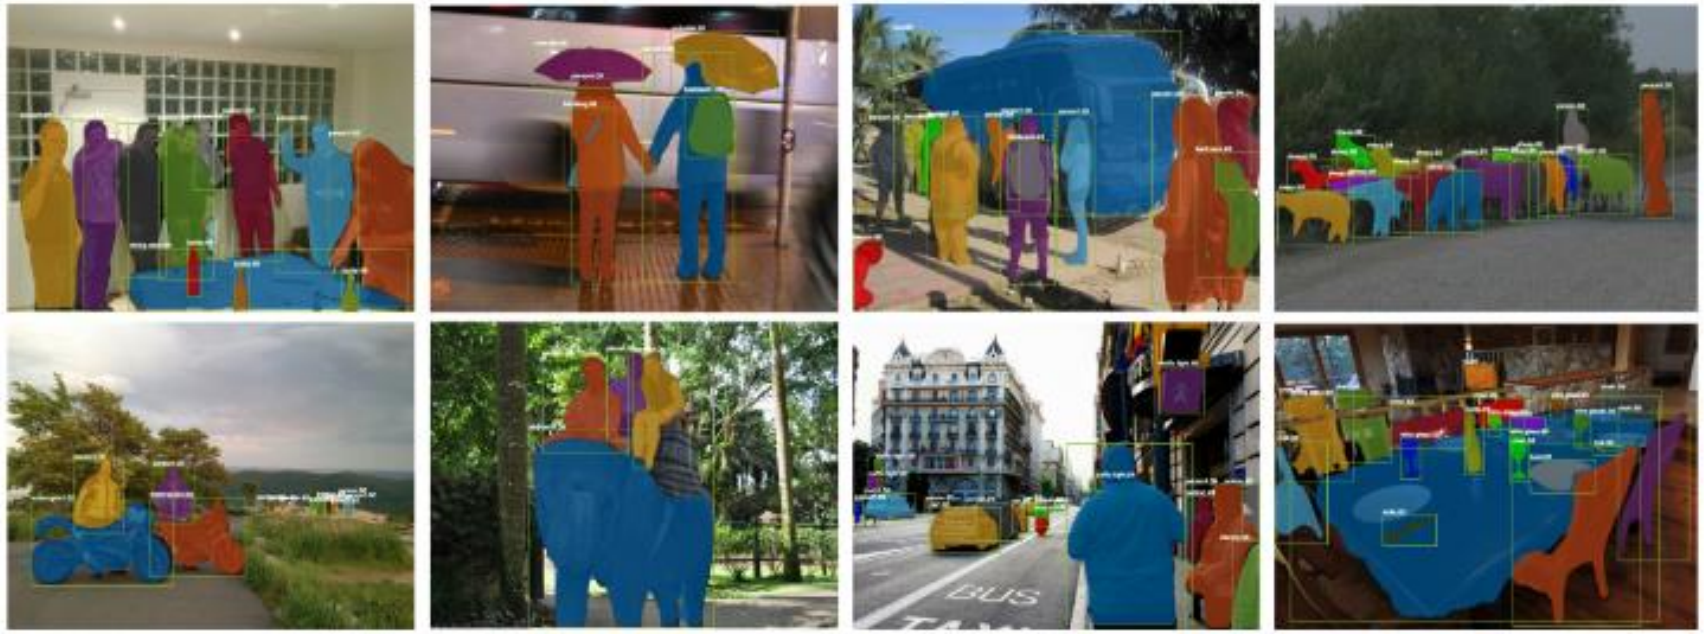

- Los resultados de las máscaras aún son burdos (baja resolución de máscara).
- Excelente generalización de instancias.

He, Kaiming, et al. "Mask r-cnn." Internal Conference on Computer Vision (ICCV), 2017.

Resultados

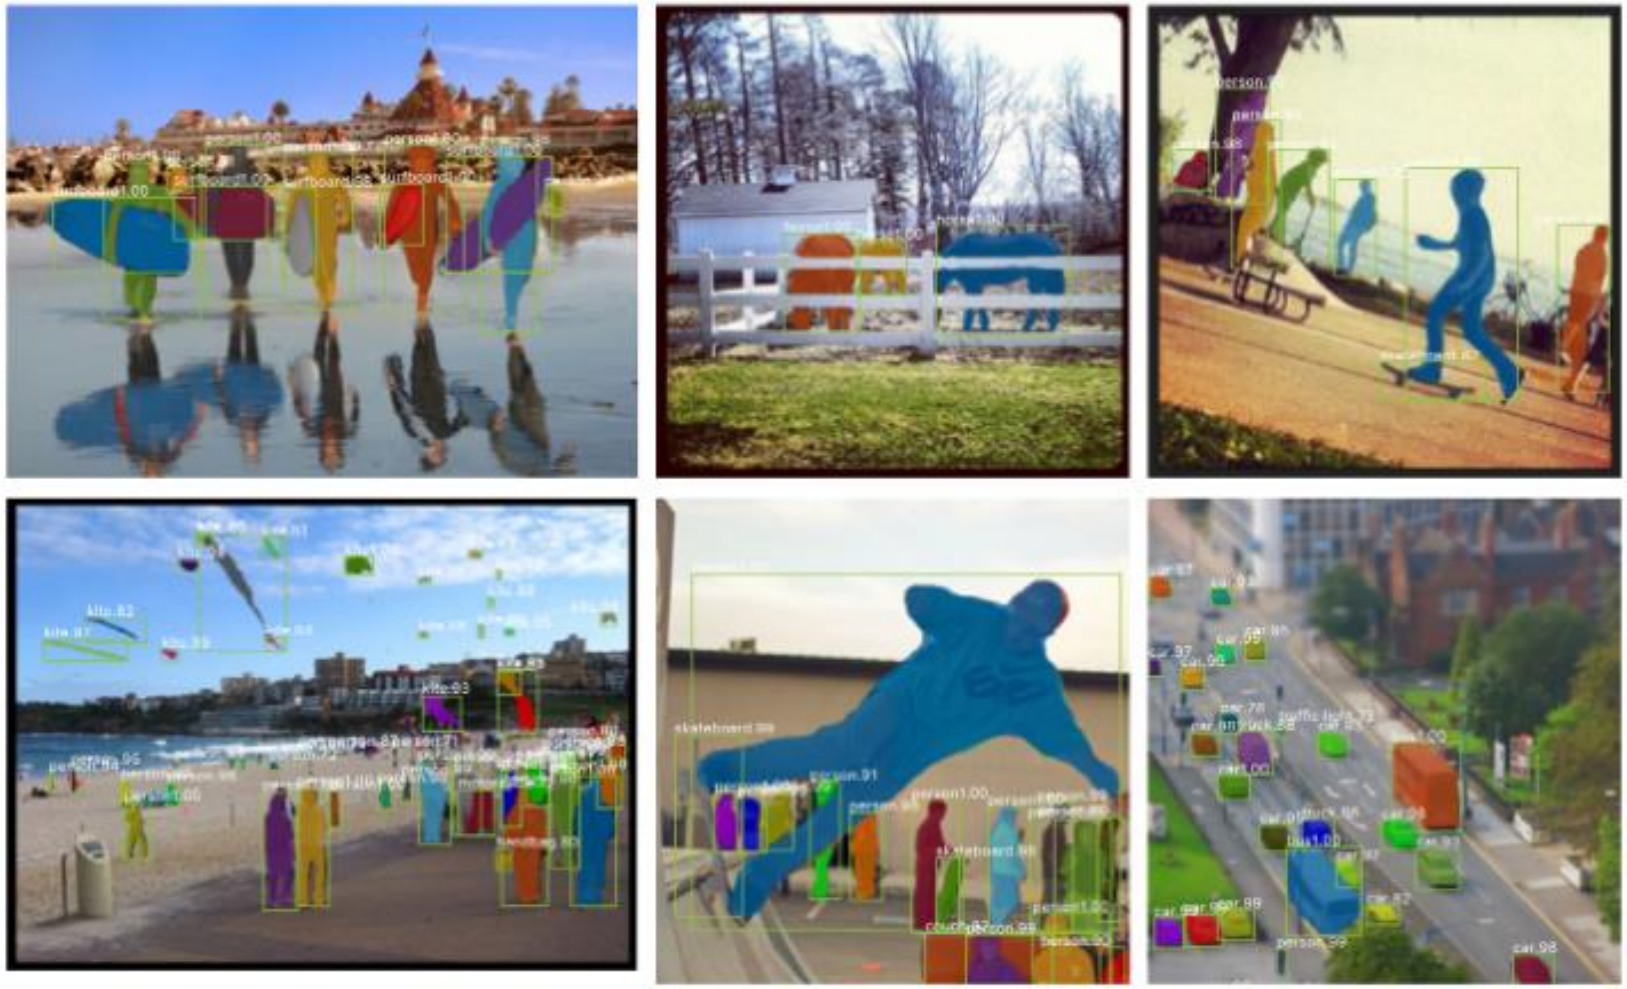

He, Kaiming, et al. "Mask r-cnn." Internal Conference on Computer Vision (ICCV), 2017.

Estado del arte y enlaces

La mayoría de los benchmarks y arquitecturas recientes se reportan aquí:

https://paperswithcode.com/area/computer-vision

Tensorflow

object detection API

Pytorch

Detectron: https://github.com/facebookresearch/Detectron

- Mask-RCNN, RetinaNet y otras arquitecturas.
- Focal loss, Redes Piramidales de Características, etc.

Red Neuronal para Visión: Conceptos Clave

Características preentrenadas como base

- ImageNet: objetos centrados, dominio de imágenes muy amplio.
- Más de 1 millón de etiquetas y muchas clases diferentes que resultan en representaciones muy **generales** y **desenredadas**.
- Mejores redes (es decir, ResNet vs VGG) tienen un **gran impacto**.

Ajuste fino (Fine tuning)

- Añadir nuevas capas sobre la capa convolucional o densa de las CNNs.
- **Ajuste fino** de toda la arquitectura de extremo a extremo.
- Utilizar un conjunto de datos más pequeño pero con etiquetas más ricas (cajas delimitadoras, máscaras...).